Экспертная оценка плана магистерской диссертации: «Прогнозирование аномальных перегрузок вычислительного сервера методами ML для раннего обнаружения DoS/DDoS-атак»

Общий вектор работы выбран верно, но заявленная научная новизна в текущей формулировке не выдержит проверки: сама идея гибрида «прогноз + реконструкция с общей функцией потерь» уже была опубликована и внедрена в промышленный продукт (Microsoft MTAD-GAT, ICDM 2020, в 2021 году встроен в Azure Multivariate Anomaly Detector), поэтому новизну нужно переформулировать как новизну применения и постановки задачи: хостовые многомерные метрики сервера, отличие DoS от легитимных пиков, время упреждения, собственный датасет. По результатам поиска мне не удалось найти публикацию 2023–2026 годов, где гибрид с совместной функцией потерь применяется именно к DoS/DDoS-детекции. Эта узкая ниша действительно свободна, но она узкая, и защищать её придётся аккуратно. Разбивка на 4 НИРС в целом логична. Её основные слабые места: НИРС-1 заранее предопределяет выбор метода, НИРС-3 перегружен, в НИРС-4 сомнительны приоритеты (десктоп-GUI и SHAP), и во всём плане нет блоков про дрейф данных, модель угроз и корректную методику оценки.

TL;DR

- **Актуальность высокая и подтверждена данными за 2025 год.** Cloudflare зафиксировал 47,1 млн DDoS-атак за 2025 год (+121% к 2024-му) и рекордную атаку мощностью 31,4 Тбит/с. В России, по данным Qrator Labs/Curator, число атак выросло на 53% в 2024 году и на 110% в I квартале 2025 года. При этом облачные сервисы детекции аномалий как отдельные продукты сворачиваются: Azure Anomaly Detector выводится из эксплуатации 1 октября 2026 года, Amazon Lookout for Metrics закрыт 10 октября 2025 года. Функциональность не исчезает, а встраивается в платформы (Fabric, CloudWatch, OpenSearch, Datadog, Dynatrace).
- **Новизна архитектуры отсутствует, новизна применения есть.** Совместная оптимизация прогноза и реконструкции известна по MTAD-GAT (2020), AER (2022) и их развитиям 2023–2025 годов (MST-GAT, CAN, TCN+VAE для микросервисов). В DDoS-литературе 2023–2026 годов встречаются только модели на одной реконструкции (LSTM-AE на CICDDoS2019) либо модели, где ошибки прогноза и реконструкции оцениваются раздельно. Формулировку новизны нужно сместить с «новой архитектуры» на «первое применение и адаптацию гибридного подхода к хостовым метрикам сервера для раннего обнаружения DoS с различением легитимных пиков».
- **Разбивка на 4 НИРС работоспособна при корректировках.** В НИРС-1 нужно убрать предрешённость AER/LSTM. НИРС-3 стоит разгрузить и добавить в него сильные простые baseline-модели, метрику VUS-PR и время обнаружения. В НИРС-4 PyQt6-приложение лучше сделать демонстрационным, а SHAP заменить или дополнить декомпозицией ошибки по признакам. Отдельно нужно добавить дрейф данных, модель угроз и разделение машин «генератор нагрузки / целевой сервер». Объём 40–50 страниц для НИРС-1 реалистичен при 50–80 источниках.

1. Актуальность направления

Вывод: тема актуальна, но позиционировать её нужно точно: не как «ещё один DDoS-детектор по сетевому трафику», а как хостовую (host-based) детекцию прикладных атак, истощающих ресурсы сервера (L7, low-rate), на пересечении кибербезопасности и AIOps.

Угроза растёт количественно и качественно.

- В отчёте Cloudflare за IV квартал 2025 года сказано, что общее число DDoS-атак за 2025 год «more than doubled to an incredible 47.1 million», а в среднем автоматически отражалось 5 376 атак в час. Рекордная атака мощностью 31,4 Тбит/с длилась всего 35 секунд. Число атак выросло на 236% между 2023 и 2025 годами. cloudflare
- Важная для работы деталь: в IV квартале 2025 года 78% атак пришлись на сетевой уровень. cloudflare Такие атаки гасятся на уровне провайдера или CDN, и один сервер по своим метрикам CPU/RAM их не «поймает», потому что канал забьётся раньше. Поэтому реалистичная ниша работы — атаки прикладного уровня и атаки на истощение ресурсов.
- Российский контекст. По Qrator Labs, число L3–L4 DDoS-атак в России в 2024 году выросло на 53% год к году. В I квартале 2025 года рост составил 110% к I кварталу 2024 года, а доля финтеха среди целей L7-атак выросла с 22,6% до 54,0%. Qrator 4PDA По итогам всего 2025 года Curator (новое имя Qrator Labs; данные SecPost от 12.12.2025) зафиксировал рост числа атак L3–L4 на 24,18%, а самая мощная атака года достигла пика 1,57 Тбит/с (сегмент «Букмекерские конторы») против рекорда 2024 года в 1,14 Тбит/с; чаще всего атаковали «Финтех» (21,73%) и «Электронную коммерцию» (15,95%).

Как ML проникает в индустрию (по каждому игроку):

- **Kaspersky MLAD** — промышленный продукт для АСУ ТП/OT, а не для серверов. Его основа — детектор Forecaster: нейросеть прогнозирует поведение объекта по недавнему прошлому, и если расхождение прогноза с фактом превышает порог, регистрируется инцидент. Kaspersky Конструктор моделей MLAD 4.0 поддерживает архитектуры Dense, TCN, CNN, RNN (GRU) и Transformer. Kaspersky Это чисто прогнозный подход, без реконструктивной составляющей. Концептуально он ближе всего к «LSTM-регрессорной» половине предлагаемой модели. Полезная для студента деталь: MLAD считает общую MSE как совокупность индивидуальных ошибок по сигналам и показывает, какие сигналы дают наибольшую ошибку (интерпретация без SHAP). Кроме того, на странице mlad.kaspersky.ru/technologies прямо сказано, что «характеристики объекта мониторинга могут измениться (новый вид сырья, замена отдельного узла, естественный износ оборудования)», и тогда модели нужно «дообучиться» (прямой аналог проблемы дрейфа).
- **PT NAD (Positive Technologies)** — анализ сетевого трафика (NTA/NDR). В 2023 году появилась функция пользовательских правил профилирования на основе ML: профилировать можно, например, число соединений или объём входящего трафика. Ptresearch Ptsecurity ML также используется для выявления DGA-доменов и приложений в шифрованном трафике. 4PDA Anti-Malware PT NAD первым среди NTA-решений получил в реестре российского ПО отметку об использовании технологий ИИ. Ptsecurity Предмет — сетевой трафик, а не ресурсы хоста; гибридной архитектуры в открытых материалах нет.

- **Microsoft Azure Anomaly Detector.** Одномерный режим построен на SR-CNN (KDD 2019), многомерный — на MTAD-GAT, где прогнозная и реконструктивная модели обучаются совместно по общей целевой функции. arXiv +3 Это единственный из перечисленных продуктов, где публично задокументирован именно гибрид «прогноз + реконструкция». Сервис выводится из эксплуатации 1 октября 2026 года, новые ресурсы нельзя создавать с 20 сентября 2023 года. Microsoft рекомендует переходить на Fabric или на open-source-проект anomaly-detector. Microsoft Learn
- **AWS (Random Cut Forest).** RCF жил в Kinesis Data Analytics for SQL (функции RANDOM_CUT_FOREST и RANDOM_CUT_FOREST_WITH_EXPLANATION), но этот сервис прекращён: приложения удаляются с 27 января 2026 года. Amazon Lookout for Metrics закрыт 10 октября 2025 года с рекомендацией использовать OpenSearch, CloudWatch, Redshift ML, QuickSight или Glue Data Quality. AWS amazon Для работы это значит, что RCF остаётся корректным baseline-методом (реализация есть в OpenSearch), но ссылаться на него как на «актуальный продукт AWS» уже неверно.
- **Darktrace** использует байесовские модели, которые динамически обновляются, и строит «pattern of life» для устройств, групп и организации в целом. Darktrace Это обучение без учителя и вероятностное моделирование на сетевом уровне; DDoS упоминается среди обнаруживаемых угроз. Summit Partners Darktrace
- **Cisco Encrypted Traffic Analytics / Secure Network Analytics.** Анализ шифрованного трафика без расшифровки, «multilayered machine learning» — сочетание обучения с учителем и без учителя. Предмет — сетевая телеметрия (NetFlow и расширенная телеметрия). По продуктовой линейке идут точечные EoL-уведомления на аппаратные платформы и лицензии, но само ПО продолжает поддерживаться. Cisco +2
- **AIOps (Datadog Watchdog, Dynatrace Davis).** Здесь ML-детекция аномалий по метрикам серверов стала стандартом. Datadog пишет, что его алгоритмы «rooted in established statistical models», адаптированные под масштабный мониторинг инфраструктуры. Davis делает акцент на причинном анализе по топологии. Logz.io Datadog Задача работы — ровно на стыке AIOps и ИБ, и это стоит использовать как аргумент актуальности.

Свежие обзоры, подтверждающие актуальность:

- Zamanzadeh Darban et al., «Deep Learning for Time Series Anomaly Detection: A Survey», ACM Computing Surveys, 2024. В таксономии прямо выделены четыре класса подходов: forecasting-, reconstruction-, representation-based и hybrid. Monash ACM Computing Surveys Это готовая рамка для главы обзора.
- «Deep anomaly detection for time series: A survey», ScienceDirect (Computer Science Review), 2025. Шесть классов методов; среди направлений развития названы foundation-модели и облегчённые (lightweight) модели. ScienceDirect
- «Deep learning techniques for DDoS attack detection: Concepts, analyses, challenges, and future directions», Expert Systems with Applications, 2025. Сравнение ML/DL-моделей по работам 2020–2024 годов. ScienceDirect
- «Detecting and Mitigating DDoS Attacks with AI: A Survey», arXiv:2503.17867, 2025. arXiv
- «A Survey of Application Layer DDoS Detection: Approaches, Models, and Datasets», Artificial Intelligence Review (Springer), 2026. Проанализировано 47 первичных работ;

ML-методы составляют 31%, гибридные — 28,6%, DL — 28,6%. Отдельно разбирается различение атак и flash crowd, то есть это прямая опора для «легитимных пиков» в датасете. Springer

- «Empowering Time Series Analysis with Foundation Models: A Comprehensive Survey», arXiv:2405.02358, 2024. arxiv
- Российский сегмент: Куценко С.М. и др., «Обнаружение вторжений в компьютерные сети на основе аномалий с помощью методов машинного обучения», журнал «Экономика. Информатика», 2025; Econom-inform-journal «Обзор методов обнаружения распределённых атак…», International Journal of Open Information Technologies (INJOIT), т. 11, № 6, 2023. Injoit Российская литература по теме заметно беднее и в основном посвящена сетевым IDS и классическому ML, что само по себе аргумент в пользу работы.

2. Оценка научной новизны

Вывод: архитектурная новизна отсутствует, а новизна применения и постановки задачи реальна, но узка. Формулировку нужно сменить до защиты НИРС-1, иначе первый же вопрос комиссии «чем это отличается от MTAD-GAT/AER?» обнулит тезис.

2.1. Индустриальные решения. Гибрид «прогноз + реконструкция с общей функцией потерь» публично задокументирован только у Microsoft (MTAD-GAT в Azure Multivariate Anomaly Detector, 2021). Его область — общие многомерные ряды (оборудование, телеметрия, тот же Airbus), а не DoS-детекция. Microsoft Community Hub Kaspersky MLAD использует только прогноз (Forecaster), причём для OT, а не для серверов. Kaspersky PT NAD, Darktrace и Cisco работают с сетевым трафиком и не используют гибрид в описанном смысле. AWS RCF — ансамбль деревьев изоляции без прогноза и реконструкции. Следовательно, гибридного продукта именно для «нагрузка сервера → DoS» на рынке нет. Но утверждать, что «гибрид — это новое», нельзя: подход прошёл путь от статьи до промышленного продукта ещё в 2021 году.

2.2. Научные публикации 2023–2026 годов.

- **DDoS:** работ с совместной оптимизацией прогноза и реконструкции не найдено.
  - Wei et al. 2023 (arXiv:2305.09475) — LSTM-автоэнкодер на CICDDoS2019, только ошибка реконструкции. arXiv +3
  - CA-CAE (CMC, 2025) — два свёрточных автоэнкодера; «joint» там означает две стадии реконструкции. TechScience
  - Работа в MDPI Telecom (2026, DOI 10.3390/telecom7030058) — CNN-LSTM-прогнозатор и автоэнкодер с раздельными порогами, без объединения оценок. DOI
  - DDoSAE (Eur. Phys. J. Plus, 2025) — только реконструкция. Springer
  - Все они работают по сетевым признакам потоков, а не по хостовым метрикам.
- **Серверные и микросервисные метрики:** ближайший аналог — «Multi-Dimensional Anomaly Detection and Fault Localization in Microservice Architectures: A Dual-Channel Deep Learning Approach…», Sensors 25(11):3396 (автор Wenhe Liu, опубликовано 28.05.2025). Это TCN (прогноз) + VAE (реконструкция) с контрастным обучением и причинным выводом, со взвешенной комбинацией ошибок и совместной функцией потерь на 12 метриках микросервисов. Но задача там — отказы и локализация неисправностей, а не атаки. Судя по аннотации MDPI, обучение полуконтролируемое («semi-supervised

learning approach that leveraged both labeled anomalies and abundant normal data»), то есть использует размеченные аномалии и не является чистым обучением без учителя; заявленные результаты — «95.4% detection accuracy, 93.8% F1-score, and 87.6% precision in fault component localization». Эту работу обязательно нужно разобрать в НИРС-1 как самого близкого конкурента.

- **Общие гибриды, тестируемые на серверных данных:** MST-GAT (arXiv:2310.11169, 2023; функция потерь $\gamma_1 \cdot L_rec + (1-\gamma_1) \cdot L_pred$) и CAN (arXiv:2306.07114, 2023) arxiv arxiv обычно проверяются на SMD (Server Machine Dataset) — метриках серверов интернет-компании. Значит, и «гибрид на метриках серверов» в широком смысле уже есть. Незанятым остаётся только сочетание «гибрид + ресурсы хоста + DoS vs легитимный пик + упреждение».

2.3. Более свежие ориентиры, чем AER 2022.

- *Трансформеры и attention-модели:* Anomaly Transformer (ICLR 2022), TranAD (VLDB 2022; тоже по сути гибрид — трансформерный кодировщик с двумя декодерами и адверсариальным обучением), GitHub ResearchGate DCdetector (2023), CATCH (2025, частотное патчирование). arxiv
- *Диффузионные модели:* D3R («Drift doesn't matter», NeurIPS 2023 — диффузионная реконструкция для нестабильных рядов, релевантна проблеме дрейфа), Selective Denoising Diffusion (arXiv:2602.23662, 2026). arxiv
- *Foundation-модели:* Chronos, MOMENT, TimesFM, Lag-Llama, Time-MoE; специализированные для детекции — TimeRadar (arXiv:2602.19068, 2026) и подходы с zero-shot-детекцией. Однако исследование arXiv:2412.19286 (2024) делает вывод, что foundation-модели временных рядов «are limited in anomaly detection and prediction», а статистические и DL-модели превосходят их по точности, эффективности и удобству. arxiv Для работы это аргумент в пользу выбора компактной специализированной модели, но хотя бы одну foundation-модель в режиме zero-shot стоит взять в сравнение как современный ориентир.
- *Ключевой методологический ориентир — TSB-AD* (Liu & Paparrizos, NeurIPS 2024): 1 070 рядов из 40 датасетов, VUS-PR рекомендован как самая надёжная метрика. Авторы пишут, что «simpler architectures and statistical methods often yield better performance». NeurIPS Отсюда прямое требование: гибрид должен обыгрывать не только ARIMA, но и сильные простые методы.

2.4. Сравнительная таблица

Решение / работа	**Год**	**Метод**	**Область**	**Близость к подходу ВКР**
Kaspersky MLAD (Forecaster)	2018 (пилот); коммерческий релиз — июнь 2021 (реестр российского ПО № 16939); 4.0 — 2023+	Прогнозная НС (Dense/TCN/CNN/GRU/Transformer), порог по ошибке прогноза	АСУ ТП, OT-телеметрия	Средняя: только прогнозная половина, не серверы и не DoS
PT NAD	2023 (ML-профилирование)	ML-профилирование метрик трафика, DGA-детекция, сигнатуры	Сетевой трафик (NTA/NDR)	Низкая: сеть, не хост; без гибрида
Azure Anomaly Detector: SR-CNN / MTAD-GAT	2019 / 2020–2021; вывод из эксплуатации 01.10.2026	Spectral Residual + CNN; GAT + совместная оптимизация прогноза и реконструкции	Общие одно- и многомерные ряды	**Высокая по архитектуре** (MTAD-GAT), низкая по задаче
AWS Random Cut Forest	2016–2026 (KDA SQL закрыт 27.01.2026)	Ансамбль случайных деревьев разрезов	Потоковые метрики	Низкая; уместен как baseline
Darktrace	2013–н.в.	Байесовские модели «pattern of life», обучение без учителя	Сеть, облако, OT	Низкая: вероятностный, не гибрид
Cisco ETA / Secure Network Analytics	2017–н.в.	Многослойное ML (с учителем и без) по телеметрии	Шифрованный сетевой трафик	Низкая
Datadog Watchdog / Dynatrace Davis	2024–2026	Адаптированные статистические модели, топологический RCA	Метрики серверов и сервисов (AIOps)	Средняя по данным, низкая по методу
MTAD-GAT (Zhao et al., ICDM)	2020	GAT + совместная функция потерь прогноз+реконструкция	Многомерные ряды (SMAP/MSL/TSA)	**Очень высокая по архитектуре**
AER (Wong et al., IEEE BigData)	2022	Двунаправленный LSTM-AE + регрессия, совместная функция потерь	Одномерные ряды (NASA, Yahoo, NAB, UCR)	Прототип работы

Решение / работа	Год	Метод	Область	Близость к подходу ВКР
MST-GAT, CAN	2023	Графы/attention + взвешенные L_rec и L_pred	Многомерные ряды, в т. ч. SMD (серверы)	Высокая
Wei et al., LSTM-AE для DDoS	2023	LSTM-AE, только реконструкция	CICDDoS2019 (потоки)	Средняя: DDoS, но без прогноза и без хостовых метрик
CA-CAE; DDoSAE	2025	Свёрточные / глубокие AE, только реконструкция	Сетевые DDoS-датасеты	Средняя–низкая
MDPI Telecom (смарт-микросети)	2026	CNN-LSTM-прогноз и AE раздельно	Трафик микросетей + DDoS	Средняя: оба типа ошибок, но не объединены
Sensors 25(11):3396 (TCN+VAE)	2025	Взвешенная сумма ошибок прогноза и реконструкции, совместная функция потерь	Метрики микросервисов, отказы	**Самый близкий аналог**, но не атаки
TranAD / Anomaly Transformer	2022	Трансформеры (адверсариальная реконструкция / association discrepancy)	Многомерные ряды	Современный конкурент для сравнения
TSB-AD (NeurIPS)	2024	Бенчмарк, 40 датасетов, VUS-PR	Методология оценки	Обязательный методологический ориентир

Рекомендуемая формулировка новизны: «Разработан метод раннего обнаружения DoS-атак прикладного уровня по многомерным хостовым метрикам вычислительного сервера на основе совместной оптимизации прогнозной и реконструктивной моделей, отличающийся (а) способом комбинирования ошибок, учитывающим различие атак и легитимных пиков нагрузки, и (б) оценкой по времени упреждения; для экспериментальной проверки сформирован размеченный датасет с тремя классами режимов». Если в НИРС-3 удастся показать выигрыш гибрида над прогнозной и реконструктивной частями по отдельности (абляция) именно на классе «легитимный пик», это и будет содержательный научный результат.

3. Оценка каждого НИРС

НИРС-1 — «Анализ предметной области и обзор научных работ…»

- **Формулировка и объём.** Название корректно и нейтрально. Хорошо, что обзор охватывает и задачи, и методы, и нерешённые проблемы.
- **Последовательность.** Главный риск в том, что тема ВКР и описание новизны уже содержат «LSTM-регрессор + автоэнкодер по аналогии с AER». Если НИРС-1 просто

подтверждает заранее выбранное решение, комиссия это увидит. Обзор должен *завершаться* обоснованным выбором класса методов по явным критериям: многомерность, работа без учителя, обучение на одном ноутбуке, интерпретируемость, задержка обнаружения. Гибрид должен появиться как вывод из сравнительной таблицы, а не как исходная посылка. Отдельный раздел должен быть посвящён различению DoS и flash crowd (легитимного пика): это давно известная трудная проблема, и она обосновывает третий класс датасета. Springer ScienceDirect

- **Обязательная структура:** (1) угрозы — классификация DoS/DDoS по уровням OSI, статистика 2024–2026 годов, почему хостовые метрики ловят именно L7-атаки и атаки на истощение ресурсов; (2) индустриальные решения (раздел 1 этого отчёта); (3) методы — статистические, классическое ML, прогнозные, реконструктивные, гибридные, трансформеры, диффузионные, foundation-модели; (4) датасеты и метрики оценки, включая критику point-adjust F1 и переход к VUS-PR; (5) нерешённые проблемы и постановка задачи.
- **Объём 40–50 страниц.** Это верхняя граница, но реалистичная для этапа, который по сути станет первой главой ВКР. По моей оценке (формального норматива ИУ8 в открытом доступе найти не удалось), типичный отчёт по НИРС в технических вузах РФ составляет 20–40 страниц, так что 40–50 — повышенное, но выполнимое требование. Чтобы текст был содержательным, нужно **порядка 50–80 источников**, из них не менее 60–70% за 2020–2026 годы. Ориентировочный состав: 5–8 обзоров, 25–35 статей по методам, 10–15 по DDoS-детекции, 5–10 документаций и отчётов вендоров, 8–12 русскоязычных работ (eLibrary/КиберЛенинка). Для сравнения, общие методические требования к НИРС в ряде вузов предусматривают минимум 10 источников, но при 40–50 страницах такой минимум неизбежно даёт «воду». Susmu Главный приём против «воды» — сводные сравнительные таблицы и формализованные критерии отбора источников (мини-методика систематического обзора: базы, ключевые запросы, период, критерии включения).
- **Достижимость:** полностью достижимо; вычислительных ресурсов не требует.

НИРС-2 — «Разработка методики и программных средств сбора данных…»

- **Формулировка.** Корректная, и последовательность верная: данные собираются до моделей. Слово «методика» обязывает описать протокол эксперимента, а не только код.
- **Критическая методическая проблема — стенд.** Если FastAPI-сервер, Locust и сборщик метрик работают на одном MacBook M1 8 GB, генератор нагрузки сам потребляет CPU и RAM, и метрики «сервера» будут загрязнены нагрузкой генератора. Датасет потеряет валидность. Решение: целевой сервер разворачивается на ThinkPad 16 GB (или в Docker/Linux-VM с жёсткими лимитами `--cpus` / `--memory`, чтобы перегрузка наступала предсказуемо), а Locust запускается на MacBook по локальной сети. Кроме того, psutil на macOS и Linux отдаёт разные наборы метрик; целевая платформа должна быть одна — Linux, как в продакшене.
- **Состав профилей.** «anomaly» нужно разбить на типы атак, иначе детектор научится одному шаблону. Нужны: HTTP-flood (объёмная L7-атака); slow-атаки вроде Slowloris и slow POST (low-rate, почти не видны по CPU, но видны по числу соединений и задержке); атака на «тяжёлый» эндпоинт (истощение CPU малым числом запросов); атака на истощение памяти. Springer Легитимные пики — flash crowd с плавным и резким фронтом

и суточная сезонность. Метрики: CPU (user/system/iowait), RAM, swap, сеть (байты и пакеты), число TCP-соединений по состояниям, открытые файловые дескрипторы, задержка p50/p95/p99, доля ошибок 5xx, RPS. Шаг дискретизации — 1 с; для «раннего» обнаружения шаг 5–10 с слишком груб.

- **Разметка.** Разметка по расписанию генератора (известны начало и конец атаки) плюс фиксация «переходных» окон. Датасет и скрипты генерации нужно публиковать, чтобы обеспечить воспроизводимость; это усилит тезис о собственном датасете.
- **Внешняя валидность.** Синтетический датасет со стенда — слабое место. Нужно заранее запланировать проверку хотя бы на одном открытом наборе: SMD для серверных метрик, TSB-AD-M для многомерных рядов, CICDDoS2019 или CIC-IDS2017 для сопоставления с сетевой DDoS-литературой. arxiv
- **Достижимость:** реально за 1 семестр. Объём данных (дни записи, десятки признаков, шаг 1 с) — это мегабайты, так что 8 GB хватает.

НИРС-3 — «Разработка и сравнение моделей»

- **Формулировка.** Логична, но это самый перегруженный этап: 2 прогнозных baseline-метода, автоэнкодер, гибрид, 2 детектора и две группы метрик.
- **Что поправить:**
  1. Baseline-методы нужно разделить на два уровня. Детекторы аномалий: Isolation Forest, RCF, простые статистические (скользящий z-score, EWMA), а также PCA или просто порог — TSB-AD показывает, что такие методы часто сильнее сложных. OpenReview Прогнозные модели: ARIMA/SARIMAX (на многомерных данных ARIMA неудобна, поэтому лучше VAR или ARIMA по ключевой метрике) и LightGBM/XGBoost на лаговых признаках.
  2. Обязательна абляция: только прогноз, только реконструкция, гибрид с раздельными моделями и сложением оценок, гибрид с общей функцией потерь. Без этого новизна не доказана.
  3. Нужен один современный конкурент: USAD, TranAD или Anomaly Transformer (готовые реализации есть), либо zero-shot foundation-модель.
  4. Порог: не фиксированный перцентиль, а EVT/POT (как в MTAD-GAT и у Kaspersky — «статистически подобранный порог»). Kaspersky CEUR-WS.org
  5. Метрики. Point-wise F1 с point-adjust завышает результаты, поэтому нужны VUS-PR и event-wise precision/recall, arxiv **время обнаружения (time-to-detect) и доля атак, обнаруженных до деградации SLA** (например, до роста p95 выше порога). Именно эта метрика превращает слово «раннее» из темы в измеримый результат. Отдельно нужна доля ложных срабатываний на классе «легитимный пик».
  6. Несколько запусков с разными seed, средние значения со стандартными отклонениями, проверка значимости.
- **Достижимость на имеющемся железе:** модели для 10–20 признаков и окон по 60–300 шагов — это десятки или сотни тысяч параметров. Они обучаются на M1 8 GB через PyTorch MPS за минуты, и Mac Mini M3 нужен в основном для сеток гиперпараметров. Узкое место — не вычисления, а время на абляцию и повторы. При плотном графике RCF можно оставить, а ARIMA сократить до одной конфигурации.

НИРС-4 — «Интеграция, объяснимость и финализация»

- **Формулировка.** Смешаны три разных задачи: инженерная интеграция, научная объяснимость и написание ВКР. Кроме того, «финальное тестирование на реальных сценариях» стоит слишком поздно: если оно выявит проблему, исправлять уже будет некогда.
- **PyQt6-десктоп.** Для ИБ-магистратуры это допустимо как демонстратор, но сервер реально мониторят агентом плюс централизованной системой, а не десктоп-программой на рабочем месте. Рекомендация: архитектура «лёгкий агент сбора (тот же psutil-сборщик) → сервис инференса (FastAPI) → клиент». PyQt6-клиент — лишь одно из представлений; альтернатива — экспорт в Prometheus/Grafana, что проще и ближе к индустрии. На GUI не стоит тратить больше 15–20% времени этапа.
- **SHAP.** Для рекуррентного гибрида SHAP (KernelSHAP/DeepSHAP) медленный и плохо интерпретируем на оконных входах. Лучше взять естественную для гибрида объяснимость — вклад каждой метрики в ошибку прогноза и реконструкции (так делают MLAD и MTAD-GAT), arXiv +2 а SHAP применить к GBM-baseline или к итоговой оценке аномальности как дополнение.
- **Достижимость:** реальна, если перенести подготовку текста ВКР в параллельный поток (главы 1–3 пишутся по итогам НИРС 1–3).

4. Риски и пробелы в разбивке

Упущено:

- **Дрейф данных и переобучение.** Нагрузка сервера нестационарна: релизы, рост аудитории, сезонность. Нужен эксперимент «обучили на неделе 1 — тестируем на неделе 3 с изменённым профилем» и стратегия переобучения (периодическое или по триггеру). Kaspersky MLAD прямо предусматривает, что при изменении характеристик объекта («новый вид сырья, замена отдельного узла, естественный износ оборудования», mlad.kaspersky.ru/technologies) модели нужно «дообучиться» — это можно использовать как индустриальное обоснование.
- **Модель угроз и адверсариальная устойчивость.** Атакующий, знающий о детекторе, может медленно наращивать нагрузку («boiling frog») или имитировать flash crowd. Нужно хотя бы описать эти сценарии и проверить на low-rate и ramp-up профилях.
- **Ограничение хостового подхода.** Метрики CPU и памяти показывают атаку только после того, как хост уже затронут. uspto Это нужно честно сформулировать и измерить упреждение относительно деградации SLA, а не относительно начала атаки.
- **Эксплуатационные аспекты:** накладные расходы агента (CPU и RAM самого сборщика), задержка инференса, поведение при недоступности сервиса инференса.
- **Приватность и этика.** Хостовые метрики обычно не содержат персональных данных, так что риск низкий. Но если в датасет попадут логи с IP-адресами или URL, придётся учитывать, что IP-адрес в ряде случаев может считаться персональными данными (152-ФЗ), и логи нужно анонимизировать. Достаточно короткого подраздела.
- **Воспроизводимость:** фиксированные версии, seed, публикация датасета и кода.

Избыточно или можно сократить: большой GUI (в объёме полноценного продукта), SHAP для рекуррентной модели, ARIMA в нескольких вариантах.

Что переставить:

- Пилотную проверку на внешнем датасете (SMD или TSB-AD) перенести из НИРС-4 в НИРС-3.
- Базовый прототип онлайн-инференса (без GUI) перенести в конец НИРС-3, чтобы в НИРС-4 оставались интеграция и полировка.
- Раздел про метрики оценки (VUS-PR, time-to-detect) закрепить в НИРС-1 как методическое решение, а в НИРС-2 учесть при разметке.

5. Итоговый вердикт

Общий вектор верен: тема востребована и хорошо ложится на программу «ИИ в ИБ», разбивка на 4 этапа логична, техническая часть выполнима одним студентом на имеющемся оборудовании. **Но работа в текущем виде уязвима по двум пунктам — новизне и методике оценки.**

Конкретные корректировки:

1. Переформулировать новизну: не «новая гибридная архитектура», а «адаптация совместной оптимизации прогноза и реконструкции к хостовым метрикам для раннего обнаружения DoS прикладного уровня с различением легитимных пиков». В обзоре явно сослаться на MTAD-GAT (2020), AER (2022), MST-GAT/CAN (2023) и TCN+VAE (Sensors, 2025) как на предшественников.
2. Уточнить тему ВКР: «…DoS-атак прикладного уровня…», либо «…DoS/DDoS-атак, направленных на истощение ресурсов сервера». Так снимается очевидный вопрос про объёмные атаки уровня L3/L4, которые хостом не ловятся.
3. В НИРС-1 не фиксировать LSTM/AER заранее: выбор метода делать выводом обзора по формализованным критериям.
4. В НИРС-2 разнести генератор нагрузки и целевой сервер по разным машинам, расширить типы атак (включая low-rate) и легитимных пиков, дискретизацию делать с шагом 1 с.
5. В НИРС-3 добавить сильные простые baseline-методы, абляцию, одного современного конкурента, порог по EVT/POT, метрики VUS-PR и time-to-detect, повторы с разными seed и внешний датасет.
6. В НИРС-4 сделать PyQt6 демонстратором поверх архитектуры «агент → сервис инференса», объяснимость строить на декомпозиции ошибки по метрикам (SHAP — как дополнение), добавить раздел про дрейф и эксплуатацию.

На что обратить внимание при защитах (руководитель — Н.В. Тутова, комиссия ИУ8):

- **НИРС-1:** быть готовым ответить: «чем ваш подход отличается от MTAD-GAT и Azure Multivariate Anomaly Detector?»; «почему хостовые метрики, а не трафик, как в PT NAD, Darktrace и Cisco?»; «какие атаки ваш подход принципиально не видит?». Показать таблицу аналогов и формальные критерии выбора метода. Упомянуть вывод из

эксплуатации Azure Anomaly Detector и Amazon Lookout for Metrics как признак того, что детекция аномалий уходит в платформы, а не как признак ненужности темы.

- **НИРС-2:** обосновать валидность стенда (разнесённые машины, лимиты ресурсов), представительность профилей и корректность разметки; показать примеры рядов по каждому классу.
- **НИРС-3:** главный слайд — абляция и сравнение с простыми методами по VUS-PR и времени обнаружения. Если гибрид не выигрывает, это тоже честный результат, но тогда вклад нужно формулировать через датасет и методику.
- **НИРС-4:** демонстрация в реальном времени на заранее отрепетированном сценарии (атака, затем легитимный пик), объяснение конкретного алерта по вкладам метрик, оценка накладных расходов и ограничений.

Caveats

- Утверждение об отсутствии гибридных работ для DDoS основано на целевом поиске (arXiv, IEEE, ScienceDirect, Springer, MDPI) и не является исчерпывающим систематическим обзором. Перед защитой НИРС-1 его нужно перепроверить по Scopus/IEEE Xplore с формализованными запросами.
- Сведения о работе Sensors 25(11):3396 (Wenhe Liu, 2025) взяты из аннотации MDPI: полуконтролируемое обучение с размеченными аномалиями, 95,4% точности детекции и 93,8% F1. Точная формула комбинирования ошибок и веса по полному тексту не проверялись.
- Список архитектур Kaspersky MLAD подтверждён для версии 4.0; для 5.x/6.0 он, судя по документации 6.0 (упоминание TCN), сохранён, но полностью не проверен. Kaspersky Kaspersky
- Внутренние материалы продуктов (особенно Darktrace, Cisco, PT NAD) закрыты. Выводы о том, что они «не используют гибрид», относятся к публично задокументированным методам.
- Оценка «20–40 страниц для типичного НИРС» и «50–80 источников» — экспертная, а не норматив ИУ8. Точные требования кафедры нужно уточнить у руководителя.
- Статистика атак из отчётов Cloudflare и Qrator Labs/Curator отражает трафик клиентов этих компаний, а не всего интернета.