


Проблема снижения размерности биометрических данных



- Сложность классификатора или регрессора (регрессионной модели) практически любого типа зависит от размерности входного вектора.
- Количество входов определяет, в том числе, временную и структурную сложность модели (классификатора), повышает требования к объему выборок, необходимых для построения.
- Снижение размерности входного пространства (пространства признаков) представляется важной задачей, предваряющей использование методов анализа данных.

- Снижение размерности не может быть однонаправленным процессом, так как количество используемой информации об объектах влияет на качество получаемой модели/классификатора
- Количество признаков определяет, в том числе, делимость (вариативность описания) объектов исследуемого множества



«Проклятие размерности»

- Сложность задачи построения эффективной модели/классификатора и задачи оптимизации возрастает экспоненциально по отношению к росту количества признаков.
- Наиболее «сложными» для моделирования/классификации являются объекты, находящиеся вне заданного радиуса от «центроида» - гиперсферы.
- При увеличении размерности пространства, доля пространства, охватываемого «гиперсферой» падает катастрофически.



- В идеализированном варианте сам регрессор или классификатор должен обладать механизмом, выделяющим из множества входных переменных действительно значимые, важные и отсеивающим нерелевантные.
- Примеры – некоторые типы нейронных сетей, самонастраивающиеся нечеткие системы и т.д.
- Тем не менее по ряду причин возникает необходимость решения задачи снижения размерности как отдельного шаг предобработки данных.

Варианты решения задачи снижения размерности

- Отбор признаков

Предполагает выбор k признаков (подмножества/поднабора) из исходного множества d признаков, которые являются наиболее информативными. Оставшиеся $(d-k)$ входов отбрасываются – не используются при построении модели/классификатора.

- Проекция признаков

Предполагает формирование нового набора k признаков, которые представляют собой комбинацию исходных d признаков.

Эффекты снижения размерности в задачах анализа данных

Целесообразно рассматривать решение задачи снижения размерности как отдельный шаг предобработки данных.

- Снижение размерности позволяет получить более быструю реализацию алгоритмов построения регрессора/классификатора.
- Определение входа как «незначимого» позволяет сэкономить ресурс на его измерение (регистрацию значений).
- Набор данных с меньшим количеством параметров легче анализируется — упрощается «извлечение знаний».
- Обеспечивается возможность визуального анализа данных, их распределение в пространстве.
- Борьба с переобучением модели/классификатора.

Выбор признаков: метод обертывания

Предполагает прямую оценку подмножества признаков через их использования для построения модели. Для выбора подмножества признаков могут использоваться два базовых подхода:

1) Прямой отбор:

- предполагается, что искомое подмножество признаков изначально является пустым
- в него пошагово один за одним добавляются признаки, позволяющие наиболее существенно сократить ошибку модели/классификатора
- отбор продолжается, пока сокращение ошибки не станет незначительным

2) Обратный отбор

- в искомое подмножество признаков изначально помещаются все d признаков
- из него пошагово один за одним исключаются признаки, обеспечивающие наименьшее приращение ошибки модели/классификатора
- отбор продолжается, пока приращение ошибки не станет слишком большим.

Выбор признаков: метод фильтров

Метод фильтров предполагает, что вместо показателя ошибки используется косвенный показатель для оценки подмножества признаков:

- оценки Пирсона
- ранговой корреляции Спирмена
- взаимная информация и т.д.

Проекция признаков: метод главных компонент

- Относится к методам проекции признаков – предполагается поиск отображения исходного пространства размерности p в пространство меньшей размерности $k < p$, обеспечивающее минимальную потерю информации
- Относится к методам «обучения без учителя» – информация о значениях выходной переменной (принадлежности к классу) не используется.
- Критерий, который должен быть оптимизирован при отображении (максимизирован) – рассеивание («дисперсия») точек.

Метод главных компонент -Базовая идея



Имеется выборка, содержащая n записей, характеризующихся p признаками:

Case	X_1	X_2	...	X_p
1	X_{11}	X_{12}	.	X_{1p}
2	X_{21}	X_{22}	.	X_{2p}
.	.	.	.	.
.	.	.	.	.
.	.	.	.	.
n	X_{n1}	X_{n2}	...	X_{np}

Метод главных компонент -Базовая идея

- Необходимо найти новый набор переменных (вектор главных компонент), полученных в форме линейного преобразования исходных переменных.
- Первая главная компонента:
выбирается из условия обеспечения наибольшего разброса (растягивания выборки) вдоль соответствующий оси.
- Вторая главная компонента выбирается из условий:
 - некоррелированность с первой главной компонентой ;
 - Обеспечение следующего по величине разброса (растягивания выборки) при проекции вдоль соответствующей оси.

Новая ось «направляется» перпендикулярно первой. И т.д.



Метод главных компонент

- Компоненты выбираются исходя из критерия максимизации разброса (проекции) выборки вдоль выбранного вектора.
- Мерой разброса для одномерной случайной величины является дисперсия (англ. –variation)
- Обобщение дисперсии для многомерного случая –случайного вектора –матрица ковариации (англ. –covariation).

$$Cov(X_i, X_j) = E\left[(X_i - E(X_i)) \cdot (X_j - E(X_j))\right] = E(X_i X_j) - E(X_i) \cdot E(X_j)$$

- Ковариационная матрица –квадратная симметричная матрица, диагональ которой заполнена значениями дисперсий соответствующих компонент случайного вектора, внедиагональные элементы –ковариации между компонентами.
- Ковариация –мера линейной зависимости двух случайных величин.

Метод главных компонент


Для ковариационной матрицы рассчитываются собственные вектора α (eigenvectors) и соответствующие собственные значения (eigenvalues) λ .

Наибольшим «растяжением» будет обладать проекция на ту ось, где коэффициенты - это координаты собственного вектора, соответствующего максимальному значению собственного числа матрицы ковариации.

Аналогично для остальных главных компонент, при этом ограничиваются k первыми главными компонентами.


Метод главных компонент. Оценка качества проекции

Обсыпной график (Scree Plot) собственных значений для каждой из главных компонент



Метод главных компонент. Оценка качества проекции

График с накопленными значениями «объясненной» дисперсии



Метод главных компонент –дополнительные шаги

- Определение типов входных переменных: вещественные, категориальные переменные.
- Кодирование категориальных данных.
- Устранение пропусков в данных:
 - исключение записей;
 - замена на среднее или медианной значение.
- Стандартизация каждого из компонентов входных векторов («нормализация данных»):
 - смещение на оценку математического ожидания;
 - масштабирование на величину оценки среднеквадратического отклонения.

Метод главных компонент. Свойства

- Упрощение структуры моделей/классификаторов
- Возможно обратное преобразование в исходное пространство, называемое «реконструкцией», восстановлением
- Метод главных компонент минимизирует ошибку реконструкции, величина которой зависит от величины собственных значений, соответствующих неиспользуемым собственным векторам
- Метод может рассматриваться как метод компрессии данных с возможностью обратного восстановления
- Восстановленные значения, например, при обработке изображений позволяют оценить потерю информации при таком сжатии

Метод главных компонент. Недостатки

- Линейное преобразование признаков
- Потеря части информации при классификации, особенно в случае, если основное разделение множества не совпадает с первыми главными компонентами
- Сложность интерпретации компонент, объединяющих различные признаки объектов

Метод главных компонент. Варианты

- При наличии обучающих данных (меток классов) –эта информации может быть использована –матрица ковариации вычисляется для каждого класса, затем выполняется взвешенное усреднение (модификация Karhunen-Loève).
- Метод обобщенных главных компонент (модификация Flury)
- Метод дискриминантного анализа (модификация Hastie, Tibshirani и Buja)
- Эмбеddинг признаков –когда количество элементов выборки меньше количества входных переменных. Предполагает поиск собственных чисел и векторов матрицы сниженной размерности.

Метод главных компонент. Альтернативные подходы

- Факторный анализ
- Сингулярное разложение
- Многомерное шкалирование
- Линейный дискриминантный анализ
- Метод нелинейного уменьшения размерности (Isomap)
- Локальное линейное внедрение
- t-DSNE (Distributed Stochastic Neighbor Embedding) –
Распределенное стохастическое вложение
- Карты Лапласа