

Метод главных компонент

Во многих задачах обработки и анализа биомедицинских данных исходное число p рассматриваемых, т. е. измеряемых на исследуемых объектах, признаков довольно велико. Для визуализации картины, простоты интерпретации и упрощения расчетов очень часто необходимо представить каждое из наблюдений в виде набора чисел, состоящего из *существенно меньшего*, чем p , числа признаков. При этом оставшиеся признаки могут либо выбираться из числа исходных, либо определяться по какому-либо правилу по совокупности исходных признаков, например как линейные комбинации последних.

Главные компоненты представляют собой новое множество исследуемых признаков

$$y^{(1)}, y^{(2)}, \dots, y^{(p)},$$

каждый из которых получен в результате некоторой линейной комбинации исходных признаков $x^{(1)}, x^{(2)}, \dots, x^{(p)}$, непосредственно измеренных на объектах. Полученные в результате такого преобразования новые признаки $y^{(1)}, y^{(2)}, \dots, y^{(p)}$ могут обладать рядом удобных статистических свойств, например быть упорядоченными по степени рассеяния в изучаемой совокупности объектов: первый признак обладает наибольшей степенью рассеяния, т. е. наибольшей дисперсией, второй — меньшей и т. д.

Рассмотрим метод вычисления главных компонент. Будем предполагать, что исследуемые наблюдения $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ извлечены из некоторой p -мерной генеральной совокупности, определяемой соответствующей вероятностной мерой. Из всех характеристик исследуемой совокупности данных существенное значение имеет ковариационная матрица $\Sigma = [\sigma_{ij}]$, где

$$\sigma_{ij} = M((x^{(i)} - a^{(i)})(x^{(j)} - a^{(j)})), \quad i, j = 1, 2, \dots, p. \quad (1.5)$$

Здесь $a^{(i)}$ — компоненты вектора $\mathbf{a}$ средних значений признаков $x^{(i)}$. Будем считать, что в (1.5) $\mathbf{a} = 0$. Этого всегда можно добиться, рассматривая в качестве исходных признаков $x^{(1)}, x^{(2)}, \dots, x^{(p)}$ не сами измерения, а их отклонения от выборочных средних значений.

Первой главной компонентой исследуемой совокупности наблюдений называется такая нормированная линейная комбинация p исходных признаков $x^{(1)}, x^{(2)}, \dots, x^{(p)}$:

$$y^{(1)} = l_{11}x^{(1)} + l_{12}x^{(2)} + \dots + l_{1p}x^{(p)} = \mathbf{L}_1^T \mathbf{X}$$

($\mathbf{L}_1^T = [l_{11} \ l_{12} \ \dots \ l_{1p}]$, $l_{11}^2 + l_{12}^2 + \dots + l_{1p}^2 = 1$), которая среди всех прочих нормированных линейных комбинаций обладает *наибольшей дисперсией*.

Вообще, i -й главной компонентой исследуемой генеральной совокупности ($i = 1, 3, \dots, p$) называют такую нормированную линейную комбинацию p исходных признаков $x^{(1)}, x^{(2)}, \dots, x^{(p)}$:

$$y^{(i)} = l_{i1}x^{(1)} + l_{i2}x^{(2)} + \dots + l_{ip}x^{(p)} = \mathbf{L}_i^T \mathbf{X},$$

которая среди всех прочих линейных нормированных ($l_{i1}^2 + l_{i2}^2 + \dots + l_{ip}^2 = 1$) комбинаций, не коррелированных со всеми предшествующими главными компонентами $y^{(1)}, \dots, y^{(i-1)}$ (т.е. $\text{cov}(y^{(i)}, y^{(j)}) = M(y^{(i)}y^{(j)}) = 0$ для $j < i$), обладает наибольшей дисперсией.

Из определения следует, что, во-первых, главные компоненты $y^{(1)}, y^{(2)}, \dots, y^{(p)}$ пронумерованы в порядке убывания их дисперсий, т.е. $Dy^{(1)} \geq Dy^{(2)} \geq \dots \geq Dy^{(p)}$, где

$$Dy^{(i)} = M(\mathbf{L}_i^T \mathbf{X})^2 = M(\mathbf{L}_i^T \mathbf{X} \mathbf{X}^T \mathbf{L}_i) = \mathbf{L}_i^T \mathbf{\Sigma} \mathbf{L}_i, \quad (1.6)$$

и, во-вторых, вектор $\mathbf{L}_i$, определяющий переход от $x^{(1)}, x^{(2)}, \dots, x^{(p)}$ к $y^{(i)}$, является i -м *собственным вектором* ковариационной матрицы $\mathbf{\Sigma}$, т.е. его компоненты $l_{i1}, l_{i2}, \dots, l_{ip}$ определяются как нормированное ($\sum_{j=1}^p l_{ij}^2 = 1$) решение системы уравнений

$$(\mathbf{\Sigma} - \lambda_i \mathbf{I}) \mathbf{L}_i = 0. \quad (1.7)$$

Эта система линейных однородных уравнений имеет ненулевое решение только в том случае, когда ее определитель равен нулю, т. е.

$$|\Sigma - \lambda \mathbf{I}| = 0, \quad (1.8)$$

где $|\cdot|$ означает определитель матрицы, λ — неизвестное число, $\mathbf{I}$ — единичная матрица.

Выражение (1.8), в котором определитель матрицы $(\Sigma - \lambda \mathbf{I})$ является многочленом степени p относительно λ , называют *характеристическим уравнением*, а его корни λ_i , $i = 1, 2, \dots, p$, — *собственными значениями* матрицы Σ .

Каждому собственному значению λ_i , определяемому из (1.8), соответствует свой собственный вектор $\mathbf{L}_i$ матрицы Σ . Составляющие этого вектора $l_{i1}, l_{i2}, \dots, l_{ip}$ для конкретного значения λ_i могут быть найдены путем решения системы уравнений (1.7).

Из сопоставления (1.6)–(1.8) следует, что

$$Dy^{(i)} = \mathbf{L}_i^T \Sigma \mathbf{L}_i = \mathbf{L}_i^T \lambda_i \mathbf{I} \mathbf{L}_i = \lambda_i.$$

Таким образом, ковариационная матрица Σ_Y главных компонент $y^{(1)}, y^{(2)}, \dots, y^{(p)}$ будет иметь вид диагональной матрицы

$$\Sigma_Y = \begin{bmatrix} \lambda_1 & 0 & 0 & \dots & 0 \\ 0 & \lambda_2 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & \lambda_p \end{bmatrix}.$$

Учитывая, что преобразование, с помощью которого осуществляется переход от исходных компонент $\mathbf{X}$ к главным компонентам $\mathbf{Y}$ ($\mathbf{Y} = \mathbf{L}^T \mathbf{X}$), *ортогонально*, исходные переменные $x^{(1)}, x^{(2)}, \dots, x^{(p)}$ можно выразить через главные компоненты:

$$x^{(i)} = l_{1i}y^{(1)} + l_{2i}y^{(2)} + \dots + l_{pi}y^{(p)}$$

(в матричной записи $\mathbf{X} = \mathbf{LY}$).


Несмотря на то что для p исходных признаков получено p главных компонент, вклад большей их части в суммарную дисперсию оказывается небольшим. Поэтому, исключив из рассмотрения те компоненты, вклад которых мал, можно существенно сократить размерность исследуемого признакового пространства.

Ортогональное преобразование $\mathbf{Y} = \mathbf{L}^T \mathbf{X}$ оставляет инвариантной обобщенную дисперсию, а также сумму дисперсий компонент исходного вектора $\mathbf{X}$, и, как следствие, суммарная дисперсия ($Dy^{(1)} + Dy^{(2)} + \dots + Dy^{(p)}$) главных компонент, равная сумме собственных чисел ($\lambda_1 + \lambda_2 + \dots + \lambda_p$), также равна сумме дисперсий ($Dx^{(1)} + Dx^{(2)} + \dots + Dx^{(p)}$) исходных признаков. На этом основании принимается решение о том, сколько последних главных компонент можно исключить из дальнейшего рассмотрения. Для этого проводится анализ изменения относительной доли дисперсии

$$q(p') = \frac{Dy^{(1)} + Dy^{(2)} + \dots + Dy^{(p')}}{Dy^{(1)} + Dy^{(2)} + \dots + Dy^{(p)}} = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_{p'}}{\lambda_1 + \lambda_2 + \dots + \lambda_p} \quad (1.9)$$

($1 \leq p' \leq p$), вносимой первыми p' главными компонентами, и определяется число компонент, которое целесообразно сохранить. Так, для

ляется число компонент, которое целесообразно сохранить. Так, для примера кривой $q(p')$, изображенной на рис. очевидно возможно сокращение размерности пространства с $p = 10$ до $p' = 3$, так как вклад семи последних главных компонент в суммарное рассеяние составляет не более 10%.



Зависимость относительной доли суммарной дисперсии исследуемых признаков $q(p')$ от числа p' первых главных компонент (случай $p = 10$)

Анализируя лишь $p' = 3$ первых, т.е. наиболее весомых главных компонент, можно объяснить основную долю, а именно 90% суммарной дисперсии, и выявить особенности рассеяния или группировки наблюдений.

Такой анализ главных компонент целесообразен, если величины $x^{(1)}, x^{(2)}, \dots, x^{(p)}$ — составляющие вектора $\mathbf{X}$ — имеют одинаковую размерность. В случае если признаки $x^{(1)}, x^{(2)}, \dots, x^{(p)}$ измеряются в различных физических единицах, на этапе предобработки необходимо перейти к безразмерным признакам $x^{*(i)}$, например, с помощью нормирующего преобразования вида

$$x_{\nu}^{*(i)} = \frac{x_{\nu}^{(i)}}{\sqrt{\sigma_{ii}}} \quad (i = 1, 2, \dots, p, \quad \nu = 1, 2, \dots, n),$$

где σ_{ii} получено из (1.5), а затем вычислять главные компоненты относительно этих признаков $x^{*(1)}, \dots, x^{*(p)}$ и их ковариационной матрицы.

Пример. Исходные данные представляют собой результат описания множества реализаций электрокардиограмм — ЭКГ (ритмограмм) набором признаков $x^{(1)}, x^{(2)}, x^{(3)}, x^{(4)}, x^{(5)}$. Эти признаки получены в процессе вычисления и анализа параметров энтропии Колмогорова, которая отражает степень сложности (хаотичности) сигналов. Выборка данных включает несколько классов ЭКГ: мерцательная аритмия (МА), нормальный ритм (НР), частая экстрасистолия (ЧЭ). Каждый класс представлен 25 объектами.

Требуется перейти от исходных признаков к главным компонентам, оценить долю дисперсии, которая обеспечивается первыми двумя главными компонентами $(y^{(1)}, y^{(2)})$, и отобразить объекты в пространстве новых признаков.

По данным измерений в соответствии с формулой (1.5) определена выборочная ковариационная матрица $\Sigma = [\sigma_{ij}]$

$$\begin{bmatrix} 0,327 & 0,177 & -4,359 \cdot 10^{-4} & -0,061 & -0,085 \\ 0,177 & 0,112 & 0,018 & -0,023 & -0,052 \\ -4,359 \cdot 10^{-4} & 0,018 & 0,026 & 0,015 & -1,636 \cdot 10^{-3} \\ -0,061 & -0,023 & 0,015 & 0,022 & 0,016 \\ -0,085 & -0,052 & -1,636 \cdot 10^{-3} & 0,016 & 0,064 \end{bmatrix}.$$

Решая в соответствии с (1.8) уравнение пятой степени относительно λ

$$\begin{vmatrix} 0,327 - \lambda & 0,177 & -4,359 \cdot 10^{-4} & -0,061 & -0,085 \\ 0,177 & 0,112 - \lambda & 0,018 & -0,023 & -0,052 \\ -4,359 \cdot 10^{-4} & 0,018 & 0,026 - \lambda & 0,015 & -1,636 \cdot 10^{-3} \\ -0,061 & -0,023 & 0,015 & 0,022 - \lambda & 0,016 \\ -0,085 & -0,052 & -1,636 \cdot 10^{-3} & 0,016 & 0,064 - \lambda \end{vmatrix} = 0,$$

находим собственные значения $\lambda_1 = 0,463$; $\lambda_2 = 0,047$; $\lambda_3 = 0,038$; $\lambda_4 = 2,7 \cdot 10^{-3}$; $\lambda_5 = 8,1 \cdot 10^{-4}$. Они упорядочены в порядке убывания их значений.

Подставляя последовательно численные значения $\lambda_1, \lambda_2, \lambda_3, \lambda_4, \lambda_5$ в систему уравнений (1.7) и решая ее относительно неизвестных $\mathbf{L}_i = [l_{i1} \ l_{i2} \ l_{i3} \ l_{i4} \ l_{i5}]^T$, $i = 1, 2, 3, 4, 5$, находим

$$\begin{aligned} \mathbf{L}_1 &= \begin{bmatrix} -0,835 \\ -0,469 \\ -0,015 \\ 0,148 \\ 0,246 \end{bmatrix}, \quad \mathbf{L}_2 = \begin{bmatrix} -0,228 \\ 0,431 \\ 0,724 \\ 0,453 \\ -0,182 \end{bmatrix}, \quad \mathbf{L}_3 = \begin{bmatrix} 0,217 \\ 0,132 \\ 0,172 \\ 0,089 \\ 0,947 \end{bmatrix}, \\ \mathbf{L}_4 &= \begin{bmatrix} 0,421 \\ -0,575 \\ 0,018 \\ 0,696 \\ -0,085 \end{bmatrix}, \quad \mathbf{L}_5 = \begin{bmatrix} 0,162 \\ -0,469 \\ 0,667 \\ -0,53 \\ -0,039 \end{bmatrix}. \end{aligned}$$

В качестве главных компонент получаем

$$\begin{aligned}y^{(1)} &= -0,84x^{(1)} - 0,47x^{(2)} - 0,02x^{(3)} + 0,15x^{(4)} + 0,25x^{(5)}, \\y^{(2)} &= -0,23x^{(1)} + 0,43x^{(2)} + 0,72x^{(3)} + 0,45x^{(4)} - 0,18x^{(5)}, \\y^{(3)} &= 0,22x^{(1)} + 0,13x^{(2)} + 0,17x^{(3)} + 0,09x^{(4)} + 0,95x^{(5)}, \\y^{(4)} &= 0,42x^{(1)} - 0,58x^{(2)} + 0,02x^{(3)} + 0,70x^{(4)} - 0,09x^{(5)}, \\y^{(5)} &= 0,16x^{(1)} - 0,47x^{(2)} + 0,67x^{(3)} - 0,53x^{(4)} - 0,04x^{(5)}.\end{aligned}$$


Здесь под $x^{(1)}$, $x^{(2)}$, $x^{(3)}$, $x^{(4)}$, $x^{(5)}$ подразумеваются отклонения параметров энтропии от их средних значений.

Вычисление относительной доли суммарной дисперсии, обусловленной пятью главными компонентами, в соответствии с формулой (1.9) дает следующие результаты:

$$\begin{aligned}q(1) &= \frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 + \lambda_5} = 0,84, \\q(2) &= \frac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 + \lambda_5} = 0,925, \\q(3) &= \frac{\lambda_1 + \lambda_2 + \lambda_3}{\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 + \lambda_5} = 0,994, \\q(4) &= \frac{\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4}{\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 + \lambda_5} = 0,999, \\q(5) &= 1.\end{aligned}$$

По результатам вычислений можно сделать вывод о том, что почти вся информация (92,5 %) об изменчивости энтропийных характеристик наблюдаемой выборки ЭКГ-данных (75 объектов) содержится в первых двух главных компонентах.

На рис. приведено изображение множества ритмограмм в пространстве двух первых главных компонент для трех классов ЭКГ (МА, НР, ЧЭ).



Представление ритмограмм классов: мерцательная аритмия (МА), нормальный ритм (НР) и частая экстрасистолия (ЧЭ) в пространстве двух первых главных компонент

Как видно из рисунка, описание объектов параметрами энтропии позволяет получить группировку объектов, соответствующую трем классам рассматриваемых ЭКГ-сигналов. Наиболее плотная группировка объектов наблюдается в классе МА. Возможно линейное разделение классов, причем, используя энтропийные характеристики ритмограмм, можно эффективно решить задачу распознавания опасного нарушения (МА) на фоне альтернативных групп аритмий (ЧЭ и НР с выраженной дыхательной аритмией).

Варианты