


ЛЕКЦИЯ № 3

Математические **ОСНОВЫ ОПТИМИЗАЦИИ**

Дифференцирование функций

1.1. Градиент функции.

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$ $f(x)$ – всюду гладкая функция.



$$\text{grad} f(x_0) = \nabla_x f(x_0) = \left\{ \frac{df}{dx_i} \right\}_{i=1,n}; \nabla_x f(x) = \left[\frac{df}{dx_1}, \frac{df}{dx_2}, \dots, \frac{df}{dx_n} \right]^T$$

для выпуклой функции:

$$f(x) \geq f(x_0) + \nabla_x^T f(x_0)(x - x_0)$$

фундаментальное неравенство выпуклых функций.

Дифференцирование функций

1.2. Субградиент и его субдифференциал.

Определение 1. Субградиентом выпуклой не всюду гладкой

функции f в точке x_0 называется вектор $\gamma = [\gamma_1, \gamma_2, \gamma_3 \dots \gamma_n]^T$,
удовлетворяющий условию $f(x) \geq f(x_0) + \gamma^T (x - x_0)$. $X \subset R^n, f(x) \in R^1$

В пространстве $E^{n+1} \subset R^{n+1}$ гиперплоскость: $z = f(x_0) + \gamma^T (x - x_0)$
касающаяся функции $f(x)$ в т. x_0 , и лежащая всюду не выше этой функции
называется опорной гиперплоскостью функции $f(x)$ в точке x_0 .

Определение 2. Субдифференциалом выпуклой необязательно гладкой

функции f в т. x_0 называется множество всех субградиентов функции $f(x)$ в т. x_0

$$df(x_0) = \left\{ \gamma_j \right\}_{j=1}^k \Big|_{x_0}$$

Обобщение: дифференциал Фреше - главная линейная часть функции $f(x)$:

$$Adx = [\gamma_j^T] dx$$

Дифференцирование функций

Теорема: Для любой точки $x_0 (\forall x_0 \in I(S_\alpha))$ элемента внутренней множества сечения уровня $df(x_0)$ - компактное множество.

1.3. Производная функции по направлению.

Определение 3. Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$, тогда производной по направлению d функции $f(x)$ в т. x_0 называется предел:



$$f'_d(x_0) = \lim_{\alpha \rightarrow 0} \frac{f(x_0 + \alpha d) - f(x_0)}{\alpha} \geq \gamma^T dx|_{x_0}$$

или
$$\left. \frac{df(x)}{dx} \right|_d = \lim_{\alpha \rightarrow 0} \frac{f(x_0 + \alpha d) - f(x_0)}{\alpha} \geq \gamma^T d$$

Обобщение: Производная Гато: $\left. \frac{df(x_0)}{d\alpha} \right|_d = \max \gamma^T d$

Из существования производной Гато не следует существование дифференциала Фреше.

Дифференцирование функций



Дифференцирование функций

1.4. Разложение функции в ряд Тейлора.

В случае n -мерного пространства переменных - разложение в ряд Тейлора.

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$, тогда, если $f(x)$ n раз дифференцируема

в т. x_0 , то $f(x_0 + \Delta x) = f(x_0) + \nabla^T f(x_0) \Delta x + \frac{1}{2} \Delta x^T H(x_0) \Delta x + \dots + O(\|\Delta x\|^T)$;

где O - остаточный член в форме Пеано;

$\nabla^T f(x_0) = \text{grad} f(x_0) = \left\{ \frac{\partial f(x_0)}{\partial x_i} \right\}_{i=1,n}$ - градиент функции $f(x)$ в т. x_0 ;

$H(x_0) = \left\{ \frac{\partial^2 f(x_0)}{\partial x_i \partial x_j} \right\}_{\substack{i=1,n \\ j=1,n}}$ - матрица Гессе 2-х частных производных в т. x_0 .

Если $\det H(x_0) \geq 0$, функция $f(x)$ в т. x_0 выпукла (если $>$ - строго).

Если $\det H(x_0) \leq 0$, функция $f(x)$ в т. x_0 вогнута (если $<$ - строго).

Если $\det H(x_0) = 0$, функция $f(x)$ в т. x_0 имеет перегиб.

Дифференцирование функций

1.5. Матрица Якоби. Якобиан.

Пусть g - операторное отображение: $g: X \rightarrow Z, X \subset E^n, Z \subset E^m$,

Тогда $\text{grad } g(x_0) = J(x_0)$ – матрица Якоби, где $J(x_0) = \left[\frac{\partial g_j(x_0)}{\partial x_i} \right]_{\substack{i=1,n \\ j=1,m}}$
а $\det(J(x_0))$ – Якобиан. $\det(J(x_0)) = |J(x_0)|$.

Если $\det J(x) \neq 0$, то система уравнений $g(x) = C$ имеет решение.

$\forall x \in X$. В этом случае существует обратное отображение

$$g^{-1}(x_0) \rightarrow x_0, [m.e. g^{-1} : Z \rightarrow X].$$

Это имеет большое значение при решении задач с неявно заданными функциями.

Дифференцирование функций

1.6. Классы дифференцируемых функций.

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$, тогда

$f(x) \in C^0(X)$ – класс непрерывных функций;

$f(x) \in C^1(X)$ – класс 1 раз дифференцируемых функций;

$f(x) \in C^2(X)$ – класс 2 раза дифференцируемых функций;

.....

$f(x) \in C^n(X)$ – класс n раз дифференцируемых функций.

Необходимые и достаточные условия существования экстремума функции

2.1. Условия существования экстремума без учета ограничений.

2.1.1. Необходимые и достаточные условия выпуклости функций.

Теорема1. (Необходимые условия).

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1 \quad \|x - \bar{x}\| \leq \varepsilon$
 $y = f(x); \forall x, \bar{x} \in X, y \in Y, f(x) \in C^1(X)$, тогда для того, чтобы $f(x)$ была выпуклой в $U_\varepsilon(x)$, необходимо, чтобы

$$f(x) \geq f(\bar{x}) + \nabla_x^T f(\bar{x}) U_\varepsilon(\bar{x}) \quad , \quad \text{где } \|x - \bar{x}\| \leq \varepsilon, U_\varepsilon(\bar{x})$$

Теорема2.(достаточные условия).

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$ и $\exists \varepsilon$, для которой $\|x - \bar{x}\| \leq \varepsilon, U_\varepsilon(\bar{x})$,
 $\forall x, \bar{x} \in X, y \in Y, f(x) \in C^2(x)$, тогда для того, чтобы $f(x)$, была выпуклой в $U_\varepsilon(\bar{x})$ достаточно, чтобы $\det H(\bar{x}) > 0$.

Необходимые и достаточные условия существования экстремума функции

2.1.2. Необходимые и достаточные условия существования экстремума функции без ограничений.

Теорема3. Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1; y = f(x); \forall x \in X, y \in Y, f(x) \in C^2(X)$.

Тогда, для того чтобы $x^e = \text{Argextr}_{x \in X} f(x)$ необходимо и достаточно, чтобы

были выполнены условия:
$$\begin{cases} \nabla f(x^e) = 0 \\ \det H(x^e) \neq 0 \end{cases}$$

При этом:
$$\begin{cases} \nabla f(x^e) = 0 \\ \det H(x^e) > 0 \end{cases} \quad \text{приводит к} \quad x^e = \text{Arg min}_{x \in X} f(x)$$

$$\begin{cases} \nabla f(x^e) = 0 \\ \det H(x^e) \leq 0 \end{cases} \quad \text{приводит к} \quad x^e = \text{Arg max}_{x \in X} f(x)$$

Необходимые и достаточные условия существования экстремума функции

2.2. Условия существования экстремума с учетом ограничений.

2.2.1. Постановка задачи:

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$ $y=f(x)$ – выпуклая функция;

$x \in X, y \in Y; f(x) \in C^1(X)$ и пусть $g: X \rightarrow Z; X \subset E^n, Z \subset E^m$
 $f(x) \in C^1(X)$

$g_i(x) \in C^1(X), j = 1..m.$ – вогнутые или выпуклые функции,

$g = [g_1(x), g_2(x), \dots, g_m(x)]^T$ а также $\forall g_j(x) = 0$ – ограничения типа равенства.

Тогда задачу поиска экстремума функции при наличии ограничений можно записать:

$$\begin{cases} x^e = \text{Arg min } f(x) \\ x_i \geq 0, i = 1..n \\ g_j(x) = 0, j = 1..m \end{cases}$$

Необходимые и достаточные условия существования экстремума функции

2.2.2.Метод множителей Лагранжа. (1788г."Аналитическая механика")

Функция вида: $L(x, \lambda) = f(x) + \sum_{j=1}^m \lambda_j g_j(x).$

Если взять вариацию от функции $L(x, \lambda)$ в $U_\varepsilon(x^e)$:

$$\delta L(x, \lambda) = \sum_{i=1}^n \frac{\partial f(x)}{\partial x_i} \delta x_i + \sum_{i=1}^n \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i} \delta x_i = 0 \quad \text{при} \quad x = x^e$$

$$\delta L(x, \lambda) = \sum_{i=1}^n \left[\frac{\partial f}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i} \right] \delta x_i = 0$$

Таким образом получаем систему уравнений : $\left[\frac{\partial f}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i} = 0 \right]_{x=x^e}$

Подбором определенных значений λ_j можно добиться того, чтобы эти уравнения удовлетворялись при $\forall i = 1..n$. Именно в точке x^e достигается стационарность функции $L(x, \lambda)$, т.е. экстремум функции $f(x)$ при заданных ограничениях $g_j(x)=0$.

Необходимые и достаточные условия существования экстремума функции

2.2.2.Метод множителей Лагранжа.

Задачу можно переформулировать следующим образом.

Требуется найти:
$$\begin{cases} x^e = \text{Arg min}_{x \in X} L(x, \lambda) \\ \lambda^e = \text{Arg max}_{\lambda \in \Lambda} L(x, \lambda) \end{cases}$$

Тогда решение задачи состоит в совместном решении уравнений:

$$\begin{cases} \frac{\partial L(x, \lambda)}{\partial x_i} = 0, i = 1..n \\ \frac{\partial L(x, \lambda)}{\partial \lambda_j} = 0, j = 1..m \end{cases} \quad \begin{cases} \frac{\partial f}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i} = 0, -n \text{ _уравнений} \\ g_j(x) = 0, -m \text{ _уравнений} \end{cases}$$

Составляются и решаются 2 системы уравнений:

Необходимые и достаточные условия существования экстремума функции

2.2.4. Область применения классического метода множителей Лагранжа.

Задача поиска экстремума методами классического математического анализа связана с удовлетворением следующих условий, накладываемых на функции:

1. Целевая функция $f(x)$ должна быть выпуклой (в случае поиска минимума).
2. Функции ограничений $g_j(x)$ должны быть вогнутыми или выпуклыми функциями.
3. Ограничения $g_j(x) = 0$ только типа равенств.

Последнее условие связано с тем, что если $g_j(x) < 0$, то классический метод множителей Лагранжа не дает единственного решения $x^e = \text{Arg min } f(x)$ и, следовательно, не работает.

3. Задачи выпуклого программирования

3.1. Формулировка задачи

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$,

$g: X \rightarrow Z; X \subset E^n, Z \subset E^m$,

$f(x) \in C^1(X), g(x) \in C^1(X)$,

$x^e = \operatorname{Arg} \min f(x), x_i \geq 0, i = 1..n$

$g_j(x) = 0, j = 1..\ell$ – ограничения типа равенств.

$g_k(x) \leq 0, k = (\ell + 1)..m$ – ограничения типа неравенств.


Обозначим множество

индексов:

$$K = \{l + 1, m\}, k \in K \text{ .}$$

3. Задачи выпуклого программирования.

3.1. Активные ограничения.



В процессе решения задачи происходит перемещение текущей точки из заданной начальной точки в конечную точку. При этом возможен выход на границу области допустимых решений X . Такие нарушенные ограничения носят название активных.

Определение множества индексов активных ограничений:

$$K_A = \left\{ k \in K \mid (\forall g_k(x) \leq 0) \wedge (\exists g_{k_A}(x) = 0) \Rightarrow k_A \in K_A \subset K \right\}$$


3.2. Функция Куна-Таккера (функция Лагранжа) для задач выпуклого программирования (1951г.)

$$L(x, \lambda, \mu) = f(x) + \sum_{j=1}^l \lambda_j g_j(x) + \sum_{k=l+1}^m \mu_k g_k(x)$$

Продифференцируем функцию $L(x, \lambda, \mu)$ по x и приравняем 0.

Если продифференцировать по μ_k , то получим неравенства $g_k(x) \leq 0$, что не позволяет получить единственное решение. Противоречие состоит в том, что для ЗВП имеется единственное решение.

$$\left. \frac{\partial L(x, \lambda, \mu)}{\partial x_i} \right|_{x^e} = 0 \Rightarrow \nabla_x f(x^e) = -\sum_{j=1}^l \lambda_j \nabla g_j(x) - \sum_{k=l+1}^m \mu_k \nabla g_k(x)$$



Множество всех
векторов

называется множеством **возможных направлений**.

Лемма: Градиент целевой функции $\nabla f(x^e)$ равен линейной комбинации градиентов функций ограничений в точке условного экстремума x^e : $-\nabla f(x^e) = \sum_{j=1}^l \lambda_j \nabla g_j(x^e) + \sum_{k=l+1}^m \mu_k \nabla g_k(x^e)$

$$\sum_{j=1}^l \lambda_j \nabla g_j(x) + \sum_{k=l+1}^m \mu_k \nabla g_k(x)$$

3.3. Теорема Куна-Таккера.

Рассмотрим задачу выпуклого программирования

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1; f(x) \in C^1(X)$

$g: X \rightarrow Z; X \subset E^n, Z \subset E^m; g(x) \in C^1(X)$

Требуется найти: $x^e = \text{Arg min } f(x), x \in X$

$x_i \geq 0, i = 1..n$,

$g_j(x) = 0, j = 1..l$,

$g_k(x) \leq 0, k = l + 1..m$. Для этого решение ЗВП должно удовлетворять следующим условиям:

$x^e \in X$,

$\mu_k g_k(x^e) = 0, \lambda_j g_j(x^e) = 0$.

$-\nabla_x f(x^e) + \sum_{j=1}^l \lambda_j \nabla g_j(x^e) + \sum_{k=l+1}^m \mu_k \nabla g_k(x^e) = 0$. Условие:

$\mu_k \begin{cases} = 0, g_k(x) < 0 \\ > 0, g_k(x) = 0 \end{cases}$.

Если эти условия выполнены, то x^e – решение ЗВП.

- называются **условиями дополняющей нежесткости**.

3.4. Теория двойственности

3.4.1. Седловая точка функции Лагранжа. Двойственность.

Рассмотрим упрощенную задачу выпуклого программирования.

Пусть заданы условия на $f(x)$ и $g(x)$ как и ранее.

$$\begin{cases} x^e = \text{Arg min } f(x), \\ x_i \geq 0, i = 1..n, \\ g_j(x) \leq 0, j = 1..m. \end{cases}$$

Тогда функция Лагранжа может быть записана:


$$L(x, \mu) = f(x) + \sum_{j=1}^m \mu_j g_j(x).$$

Рассмотрим случай, когда $x = x^e, \mu = \mu^e$:

$$L(x, \mu^e) \geq L(x^e, \mu^e) \geq L(x^e, \mu).$$

Таким образом седловая точка функции Лагранжа (функции Куна-Таккера) является $[x^e, \mu^e]^T$.

Именно эта точка является решением ЗВП.



3.4. Теория двойственности.

Задача может быть поставлена как минимаксная и может быть разбита на решение двух задач:

1. Прямая задача – $x^e = \text{Arg} \min_{x \in X} \max_{\mu \in M} L(x, \mu)$
при $\mu = \mu(x)$ – множитель Лагранжа (Куна-Таккера) .
2. Двойственная задача – $\mu^e = \text{Arg} \max_{\mu \in M} \min_{x \in X} L(x, \mu)$
при $x = x(\mu)$ – переменная проектирования.

Пример: Задача линейного программирования.

Прямая задача: $\min c^T x; Ax = b; x_i \geq 0$

Двойственная задача:

$$L(x, \mu) = c^T x + (A^T \mu - b^T) x = (c^T + A^T \mu) x - b^T \mu;$$
$$\max \mu^T b; \mu^T A = -c; \mu_j \leq 0.$$

4. Алгоритм и сходимость алгоритмов

4.1. Понятие алгоритма. Алгоритмические отображения.

Определение. Алгоритмом называется итеративный процесс вычислений, который порождает последовательность точек в соответствии с предписанным набором правил, включающим критерий окончания этого процесса.

Алгоритмическое отображение.

Пусть $A: X \rightarrow X; X \subset E^n, x^{(k+1)} = A(x^{(k)})$ для $\forall k \in \mathbb{N}$,

Таким образом $x^{(k+1)} = A(A(\dots(A(x^0))\dots))$, где $x^{(0)}$ - начальная точка.


В качестве реализации алгоритмического отображения методов оптимизации может быть выбрана некоторая функция спуска, зависящая от переменных проектирования $\varphi(x^{(k)})$.

При этом она должна удовлетворить условию $\varphi(x^{(k+1)}) \leq \varphi(x^{(k)})$

В качестве функции спуска может быть использована целевая функция $f(x)$ или градиент целевой функции $\nabla f(x)$.

4. Алгоритм и сходимость алгоритмов

4.2. Композиция алгоритмических отображений.



1. Выбор направления уменьшения функции спуска d – в области возможного направления. Например $d \in E^n$

Этот алгоритм обозначим D

2. Выбор шага $\alpha \rightarrow (\varphi(x^{(k)} + \alpha^{(k)} * d^{(k)}) \leq \varphi(x^{(k)}))$
 $\alpha^{(k)e} = Arg \min \varphi(x^{(k)} + \alpha^{(k)} * d^{(k)})$

Этот алгоритм обозначим U .

3. Если решается задача с ограничениями, то необходимо ввести еще один алгоритм L , учитывающий наличие ограничений.


Тогда общий алгоритм будет композицией алгоритмов: $A(\varphi(x)) = L * U * D(\varphi(x))$

4. Алгоритм и сходимость алгоритмов

4.2. Критерий окончания процесса оптимизации.

Точка зрения математика состоит в нахождении точного решения.

Точка зрения инженера состоит в определении области $\Omega_\varepsilon \subset X$ близкой к оптимальной. В связи с этим существует несколько критериев останова в зависимости от точности решаемой задачи.



Точка зрения инженера.

Критерии останова алгоритма.

1. $\|x^{(k+N)} - x^{(k)}\| < \delta$
2. $\frac{\|x^{(k+1)} - x^{(k)}\|}{\|x^{(k)}\|} < \delta$
3. $|\varphi(x^{(k)}) - \varphi(x^{(k+N)})| < \varepsilon$
4. $\frac{\varphi(x^{(k)}) - \varphi(x^{(k+1)})}{\varphi(x^{(k)})} < \varepsilon$

4. Алгоритм и сходимость

алгоритмов

4.3. Скорость сходимости алгоритмов.

Пусть $\{x^{(k)}\}$ сходится к $\bar{x}$, тогда, если выполняются неравенства:

$$(1.) \lim_{k \rightarrow \infty} \sup \frac{\|x^{(k+1)} - \bar{x}\|}{\|x^{(k)} - \bar{x}\|} = \beta, \quad \beta < 1, \quad \beta - \text{коэффициент сходимости,} \\ - \text{линейная сходимость,}$$

$$(2.) \lim_{k \rightarrow \infty} \sup \frac{\|x^{(k+1)} - \bar{x}\|}{\|x^{(k)} - \bar{x}\|^\gamma} < \beta < +\infty, \gamma > 1, \gamma - \text{порядок сходимости,} \\ - \text{суперлинейная сходимость.}$$

При $\gamma = 2$ – квадратичная сходимость.