

МАТЕМАТИЧЕСКИЕ ОСНОВЫ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Каганов Ю.Т.

к.т.н., доцент каф. ИУ-5

«Системы обработки информации и управления»

ЛЕКЦИЯ № 9

- 1. Элементы теории вероятностей.**
- 2. Машинное обучение и минимизация эмпирического риска.**
- 3. Теорема Байеса. Трансдукция.**
- 4. Регрессионный анализ и методы построения целевых функций.**

ЭЛЕМЕНТЫ ТЕОРИИ ВЕРОЯТНОСТИ

Понятие вероятности

Вероятность – это мера, заданная на множестве событий, которые удовлетворяют трем аксиомам:

1. Мера каждого события находится в пределах от 0 до 1. Это утверждение записывается как $0 \leq P(X = x_i) \leq 1$, где X – случайная переменная, представляющая событие, а x_i – возможное значение X . Обычно принято обозначать случайные переменные прописными буквами, а их значения – соответствующими строчными.
2. Мера всего множества равна 1, а это означает, что $\sum_{i=1}^n P(X = x_i) = 1$.
3. Вероятность объединения взаимоисключающих событий равна сумме вероятностей отдельных событий, т.е. $P(X = x_1 \vee X = x_2) = P(X = x_1) + P(X = x_2)$, где события x_1 и x_2 являются взаимоисключающими.

Вероятностная модель состоит из пространства выборок взаимоисключающих возможных результатов вместе с вероятностной мерой каждого результата. Например: «солнечно», «облачно», «дождь», «снег».

ПЛОТНОСТЬ ВЕРОЯТНОСТИ

- Будем использовать запись $\mathbf{P}(X)$ для обозначения вектора значений $\langle P(X = x_1), \dots, P(X = x_n) \rangle$. Используем также запись $P(x_i)$ вместо $P(X = x_i)$ и $\sum_{i=1}^n P(x_i)$ вместо $\sum_{i=1}^n P(X = x_i)$.
- Условная вероятность $P(B / A)$ определяется как $P(B \cap A) / P(A)$. Переменные A и B являются условно независимыми, если $P(B / A) = P(B)$ (или равным образом $P(A / B) = P(A)$).
- Непрерывные переменные имеют бесконечное количество значений, и если распределение вероятностей этих значений не характеризуется пиковыми значениями в отдельных точках, то вероятность любого отдельно взятого значения равна 0. Поэтому имеет смысл говорить о значении вероятности в пределах некоторого диапазона. Это реализуется с помощью **функции плотности вероятности**, которая имеет несколько иной смысл по сравнению с дискретной функцией вероятности. Поскольку вероятность $P(X = x)$ - т.е. вероятность, которую X имеет при точном значении x - равна нулю, мы будем использовать другую меру: отношение вероятности того, что X попадает в интервал вокруг x , к ширине этого интервала, измеряемой в пределе приближения ширины этого интервала к нулю. Таким образом **функция плотности вероятности** $P(X = x)$ определяется как

$$P(x) = \lim_{dx \rightarrow 0} P(x \leq X \leq x + dx) / dx$$

Функция плотности вероятности должна быть неотрицательной при всех x и соответствовать следующему требованию:

$$\int_{-\infty}^{\infty} P(x) dx = 1$$

Кумулятивное распределение $F_X(x)$ определяется как вероятность того, что случайная величина будет меньше x .

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x P(u) du.$$

РАСПРЕДЕЛЕНИЕ ГАУССА (нормальное распределение)

Распределение Гаусса является одним из наиболее важных распределений вероятностей. Для этого распределения используем обозначение $N(x; \mu, \sigma^2)$ как функции от x со средним значением μ и среднеквадратическим отклонением σ (и, следовательно с дисперсией σ^2). Нормальное распределение определяется следующей формулой:

$$N(x; \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

где x – непрерывная переменная, изменяющаяся в пределах $-\infty$ до $+\infty$. Если среднее $\mu = 0$ и дисперсия $\sigma^2=1$, то имеет место частный случай нормального распределения, который называется **стандартным нормальным распределением**. Если распределение задано в d -мерном пространстве на векторе $\mathbf{x}$ в пространстве с d измерениями, то оно представляет собой много **многомерное гауссово распределение**:

$$N(\mathbf{x}; \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} e^{-\frac{1}{2}((\mathbf{x}-\mu)^T \Sigma^{-1} (\mathbf{x}-\mu))},$$

где μ – **вектор средних**, а Σ – **ковариационная матрица** этого распределения.

ЦЕНТРАЛЬНАЯ ПРЕДЕЛЬНАЯ ТЕОРЕМА

В *центральной предельной теореме* утверждается, что среднее n случайных переменных приближается к нормальному распределению по мере того, как n стремится к бесконечности. Такому свойству подчиняется почти любая коллекция случайных переменных, при том условии, что значение дисперсии любого конечного подмножества переменных не доминируют над значениями других конечных подмножеств.

Математическое ожидание случайной величины $M(X)$, представляет собой среднее значение, взвешенное по вероятности каждого значения. Для дискретной переменной это

$$M(X) = \sum_x x_i P(X = x_i).$$

Для непрерывной переменной суммирование следует заменить интегралом и использовать функцию плотности вероятности, $P(x)$:

$$M(X) = \int_{-\infty}^{\infty} xP(x)dx .$$

Для любой функции $f(X)$ можно также записать

$$M(f(X)) = \int_{-\infty}^{\infty} f(x)P(x)dx$$

СТАТИСТИЧЕСКИЕ ХАРАКТЕРИСТИКИ РАСПРЕДЕЛЕНИЯ

1. **Дисперсия** $D[X]$ — математическое ожидание квадрата отклонения случайной величины от её математического ожидания:

$$D[X] = M((X - M(X))^2)$$

2. **Стандартное отклонение** σ — квадратный корень из дисперсии (поэтому дисперсия часто обозначается как σ^2).

3. **Среднее квадратическое** s для набора значений (чаще всего это выборка значений случайной величины) представляют собой квадратный корень из среднего арифметического квадратов значений в наборе:

$$s(x_1, x_2, \dots, x_n) = \sqrt{\frac{x_1^2 + x_2^2 + \dots + x_n^2}{n}}.$$

4. **Ковариация** двух случайных величин определяется как математическое ожидание произведения разностей их значений и соответствующих средних значений:

$$Cov(X, Y) = M((X - \mu_X)(Y - \mu_Y)).$$

5. **Ковариационная матрица** $\Sigma_{i,j}$, часто обозначается как S . Является матрицей составленной из попарных ковариаций между элементами вектора случайных величин. Принимая, что вектор представлен как $X = (X_1, X_2, \dots, X_n)^T$, элементами ковариационной матрицы будут:

$$S_{i,j} = Cov(X_i, X_j) = M((X_i - \mu_i)(X_j - \mu_j)).$$

ВЫБОРКА

Выборка — это часть общей совокупности возможных элементов случайной величины, полученная в результате некоторого эксперимента. Мы не знаем, каково будет распределение вероятностей для любой конкретной выборки, но в пределе достаточно большой набор данных выборок будет приближаться к той же функции распределения плотности вероятности, которая свойственна общей совокупности элементов этой случайной величины.

Равномерное распределение характеризуется тем, что каждый элемент общей совокупности в равной степени (равномерно) вероятен. Поэтому, если мы говорим, что «случайная величина имеет равномерное распределение в диапазоне целых чисел от 0 до 99», то это означает , что при выборке с одинаковой вероятностью может быть получено любое целое число из этого диапазона.

ОБУЧЕНИЕ МОДЕЛИ, ТЕОРЕМА БАЙЕСА И ТРАНСДУКЦИЯ

ОБУЧЕНИЕ МОДЕЛИ

Введем обозначения:

$\theta = \langle W, b \rangle$ — кортеж весов и порогов (соответствует параметрам модели).

$D = \langle X, Y \rangle$ — кортеж исходных данных (соответствует входным и выходным данным).

θ^* — параметры модели после окончания обучения (оптимальные параметры).

$L(\theta)$ — функция потерь в процессе обучения (целевая функция в процессе оптимизации).

Процесс оценивания θ по D называется *обучением модели*. Он составляет основное содержание машинного обучения. Основной способ получения оценок сводится к задаче оптимизации:

$\theta^* = \underset{\theta}{\operatorname{argmin}} L(\theta)$. При этом процесс оптимизации состоит в подборе таких $\theta(n+1) = \theta(n) + \Delta\theta(n)$, при которых $L(\theta(n+1)) \leq L(\theta(n))$.

Обучение модели и теорема Байенса

Обучение модели:

Пусть имеется некоторая модель (гипотеза, теория) - M , которая предварительно (априорно) получена из наблюдаемых исходных данных - D . Тогда для обучения этой модели M необходимо обеспечить соответствие этой модели новым данным D' .

Теорема Байеса:

$$P(M'|D') P(D') = P(M)P(D|M),$$

Откуда получаем формулу Байеса:

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$

Формула Байеса

Формула Байеса служит для вычисления распределения вероятностей возможных значений модели - M при наличии наблюдаемых данных — D .

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$

$P(M)$ — априорная вероятность, связанная со структурой модели.

$P(D|M)$ — априорная вероятность данных при заданной модели.

$P(D')$ — апостериорная вероятность данных.

$P(M'|D')$ — апостериорная вероятность модели при известных данных.

Задача познания состоит в том, чтобы максимизировать апостериорную вероятность $P(M'|D')$.

Трансдукция

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$

Эта формула имеет непосредственное отношение к процессу познания. Она носит итеративный характер. В этом случае соответствующие вероятности можно трактовать следующим образом:

$P(M)$ – переход от индуктивных к дедуктивным моделям (абдукция).

$P(D|M)$ – переход от формулировки модели к соответствию с данными (дедукция).


$P(D')$ – переход от гипотетических данных к экспериментальным (аддукция).

$P(M'|D')$ – переход от экспериментальных данных к построению новой модели (индукция).

Трансдукция

(“Сначала восходят к аксиомам, а затем спускаются к практике” Ф. Бэкон)

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$



ОБУЧЕНИЕ И ОЦЕНКА МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ (MLE)

Введем обозначения:

MLE (Maximum Likelihood Estimation) – оценка максимального правдоподобия определяется следующим образом:

$$\theta^* = \underset{\theta}{\operatorname{argmax}} p(D|\theta) \text{ или } \theta^* = \underset{\theta}{\operatorname{argmin}} \{-p(D|\theta)\}$$

Если учесть, что обучающие примеры независимо выбраны из одного и того же распределения, то правдоподобие принимает вид

$p(D|\theta) = \prod_{n=1}^N p(y_n|x_n, \theta)$ – это дает возможность при логарифмировании перейти от оператора произведения к оператору суммирования. Таким образом получаем

$$\log p(D|\theta) = \sum_{n=1}^N \log[p(y_n|x_n, \theta)].$$

Тогда задача состоит в максимизации $\theta^* = \underset{\theta}{\operatorname{argmax}} \sum_{n=1}^N \log p(y_n|x_n, \theta)$. Или, учитывая удобство минимизации запишем функцию с отрицательным знаком

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \left(- \sum_{n=1}^N \log [p(y_n|x_n, \theta)]. \right)$$

ФУНКЦИЯ ПРАВДОПОДОБИЯ

Правдоподобие – это вероятность получения имеющихся наблюдений для заданных параметров модели. Пусть имеется n наблюдений $x_1, x_2, \dots, x_n$. Будем предполагать, что все наблюдения независимы и подчиняются одному и тому же нормальному распределению со средним μ и дисперсией σ^2 .

Тогда функция правдоподобия может быть выражена:

$$P(\text{данные/параметры модели}) = P(x_1, x_2, \dots, x_n / \mu, \sigma^2).$$

Поскольку все наблюдения независимы, то можно представить как факторизованную модель:

$$P(\text{данные/параметры модели}) = \prod_{i=1}^n P(x_i / \mu, \sigma^2).$$

Учитывая нормальность распределения запишем функцию правдоподобия:

$$P(\text{данные/параметры модели}) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} e^{\frac{-(x_i - \mu)^2}{2\sigma^2}}.$$

МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

Метод максимального правдоподобия – (maximum likelihood estimation, MLE) – это метод оценивания неизвестных параметров распределения или модели путем максимизации функции правдоподобия. Т.е. максимизации вероятности распределения данных при заданных параметрах модели.

Функцию правдоподобия можно представить в виде:

$$P(\text{данные/параметры})=L(\theta) = \prod_{i=1}^n P(x_i / \theta).$$

Чтобы максимизировать функцию вероятности $L(\theta)$, необходимо продифференцировать $L(\theta)$ по θ и приравнять 0. Более удобно максимизировать не саму функцию правдоподобия, а ее логарифм. Т.е. $\log L(\theta)$. Поскольку логарифм - монотонно возрастающая функция, то с ростом параметра θ будет максимизироваться и логарифм. С точки зрения математики производная от логарифма находится проще.

Поэтому можно записать: $\log L(\theta) = \sum_{i=1}^n \log(P(x_i / \theta))$. Для того, чтобы найти максимум следует $\log L(\theta)$ продифференцировать и приравнять нулю. Учитывая, что максимизация соответствует минимизации функции взятой с отрицательным знаком, получим

$$\theta^* = \text{Argmin}(-\log L(\theta))$$

МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

В случае классификации можно использовать *схему Бернулли*, которая предполагает взаимоисключающие и исчерпывающие исходы экспериментов. При этом возможными исходами эксперимента по схеме Бернулли может быть «успех» или «неудача». Пусть p – вероятность успеха. Тогда, в силу того, что этими двумя событиями исчерпывается все выборочное пространство, вероятность неудачи равна $p - 1$. Будем считать, что успешному исходу соответствует значение $x = 1$, а неудачному - $x = 0$, Тогда вероятность успеха или неудачи можно выразить формулой

$$P(X = x) = f(x) = p^x(1 - p)^{(1-x)}$$

МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

Для каждой точки данных $(y^i / x^i, \theta) - \text{Bernulli}(1, p)$, тогда для функции вероятности можно записать:

$$P(y^i / x^i, \theta) = f(x) = (1 - p_i)^{(1-y^i)},$$

где $p_i = \frac{1}{(1+e^{(-\theta^T x)})}$.

Перепишем функцию правдоподобия в виде $L = P(\text{данные} / \text{модель}) = P(D^1, D^2, \dots, D^m / \theta)$, где D^i представляет собой i - й обучающий пример (y^i / x^i) .

Исходя из допущения о независимости обучающих примеров, можно представить $L(\theta)$ в следующем факторизованном виде

$$L(\theta) = P(D^1, D^2, \dots, D^m / \theta) = \prod_{i=1}^m P(D^i / \theta).$$

Логарифмируя обе части этого равенства, преобразуем произведение вероятностей в сумму их логарифмов $\log L(\theta) = \sum_{i=1}^m \log P(D^i / \theta)$. Так как $P(D^i / \theta) = k P(y^i / x^i, \theta)$. В результате получаем $\log L(\theta) = \sum_{i=1}^m (\log k + y^i \log p_i + (1 - y^i) \log(1 - p_i))$. Учитывая эквивалентность максимизации и минимизации функций получим

$$\theta^* = \text{Argmin}(-\log L(\theta)), \text{ где } p_i = \frac{1}{(1+e^{(-\theta^T x)})}.$$

ЛИНЕЙНАЯ РЕГРЕССИЯ

Рассмотрим нормальное (гауссово) распределение:

$$N(y|W^T x + b; \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-W^T x-b)^2}{2\sigma^2}\right)$$

В многомерном случае мы получим:

$$N(\mathbf{y}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{n/2}} \exp\left[-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right],$$

где $\boldsymbol{\mu} = \mathbf{E}[\mathbf{y}] \in \mathbf{R}^n$ - вектор средних, а $\boldsymbol{\Sigma} = \text{Cov}[\mathbf{y}]$ – ковариационная матрица размера $n \times n$, определяются следующим образом $\text{Cov}[\mathbf{y}] = \mathbf{E}[(\mathbf{y} - \mathbf{E}[\mathbf{y}])(\mathbf{y} - \mathbf{E}[\mathbf{y}])^T]$. Что равно:

$$\text{Cov}[\mathbf{y}] = \begin{bmatrix} V[Y_1] & \text{Cov}[Y_1 Y_2] & \text{Cov}[Y_1 Y_n] \\ \text{Cov}[Y_2 Y_1] & V[Y_2] & \text{Cov}[Y_2 Y_n] \\ \text{Cov}[Y_n Y_1] & \text{Cov}[Y_n Y_2] & V[Y_n] \end{bmatrix}, \text{ где } \text{Cov}[Y_i Y_j] = \mathbf{E}[Y_i Y_j] - \mathbf{E}[Y_i] \mathbf{E}[Y_j], \text{ а } V[Y_j] = \text{Cov}[Y_i Y_i]$$

Расстояние Махаланобиса:

Если рассматривать логарифмическую вероятность в точке $\mathbf{y}$, то мы получим

$$\log p(\mathbf{y}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \left[-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right] + \text{const.} \text{ Тогда расстояние Махаланобиса } \Delta \text{ между } \mathbf{y} \text{ и } \boldsymbol{\mu} \text{ выразим}$$
$$\Delta^2 = (\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu}).$$

ЛИНЕЙНАЯ РЕГРЕССИЯ

Предположим, что имеется m выборок $(y^1 / x^1, y^2 / x^2, \dots, y^m / x^m)$. Можно вычислить функцию стоимости $J(\theta) = \sum_{i=1}^m (\theta^T x^i - y^i)^2$. Можно минимизировать эту функцию относительно θ , чтобы определить параметры модели. Таким образом можно записать

$$\theta^* = \text{Argmin} \sum_{i=1}^m (\theta^T x^i - y^i)^2.$$

Выразим вектор прогноза Y^p как $Y^p = X\theta$, а погрешность $e = X\theta - Y$. Тогда $J(\theta)$ можно выразить в виде квадрата l^2 нормы вектора невязки

$$\|e\|_2^2 = \|X\theta - Y\|_2^2 = (X\theta - Y)^T (X\theta - Y).$$

Можно записать вероятность для линейной регрессии следующим образом

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2), \text{ где } \theta = (W, b, \sigma^2)$$

Если дисперсия фиксирована и не зависит от исходных данных, то такая модель называется *гомоскедастической регрессией*.

Если дисперсия зависит от входных данных, то такая модель называется *гетероскедастической регрессией*. В линейной постановке получаем

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2(W_0^T x))$$

ЛИНЕЙНАЯ РЕГРЕССИЯ

Линейная регрессия соответствует модели

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2)$$

где $\theta = (W, \sigma^2)$. Будем считать, что σ^2 фиксировано. Задача состоит в определении W .

1) Определим **отрицательный логарифм правдоподобия NLL**:

$$NLL(W) = - \sum_{n=1}^N \log \left[\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp \left(-\frac{1}{2\sigma^2} (y_n - W^T x_n)^2 \right) \right].$$

2) Отбросив несущественные постоянные слагаемые, получим сумму квадратов невязок **RSS**.

$$RSS(W) = \sum_{n=1}^N (y_n - W^T x_n)^2 = \sum_{n=1}^N (r_n)^2, \text{ где } r_n - \text{невязка.}$$

3) Поделив $(r_n)^2$ на число примеров получим **среднеквадратическую ошибку MSE**.

$$MSE(W) = \frac{1}{N} RSS = \frac{1}{N} \sum_{n=1}^N (y_n - W^T x_n)^2.$$

4) Извлекая квадратный корень получим **корень из среднеквадратичной ошибки RMSE**

$$RMSE(W) = \sqrt{MSE(W)} = \sqrt{\frac{1}{N} \sum_{n=1}^N (y_n - W^T x_n)^2}$$

ЛИНЕЙНАЯ РЕГРЕССИЯ

Для вычисления *MLE* – оценки максимального правдоподобия можно минимизировать любую из предложенных оценок – *NLL, RSS, MSE, RMSE*. Во всех случаях результат будет один и тот же, поскольку целевая функция будет одной и той же .

Рассмотрим $RSS(W) = \sum_{n=1}^N (y_n - W^T x_n)^2 = \|xW - y\|_2^2 = (xW - y)^T (xW - y)$.

Для того, чтобы получить оптимальные значения

$$W_{MLE} = \text{Argmin} RSS(W) = (X^T X)^{-1} X^T y$$

Эта оценка обыкновенных наименьших квадратов (*OLS*) эквивалентна *MLE*

ДИВЕРГЕНЦИЯ КУЛЬБАКА-ЛЕЙБЛЕРА И ПЕРЕКРЕСТНАЯ ЭНТРОПИЯ

Понятие *расстояние (дивергенция) Кульбака-Лейблера* пришло из теории информации. Оно является мерой разницы между двумя вероятностями распределения Q и P . Будем считать распределение P – истинное распределение, Q – его приближение. Дивергенция Кульбака – Лейблера от распределения P до распределения Q обозначается $KL(P||Q)$ и определяется следующим образом

$$KL(P||Q) = \int \log \frac{dP}{dQ} dP, \text{ где интеграл берется по всему пространству исходов, общих для } P \text{ и } Q.$$

Рассмотрим следующие случаи:

- Q и P – дискретные случайные величины, заданные на дискретном множестве

$$X = \{x_1, \dots, x_n\}. \text{ Расстояние Кульбака – Лейблера } KL(P||Q) = \sum_i p(x_i) \log \frac{p(x_i)}{q(x_i)}.$$

- Q и P – непрерывные случайные величины в пространстве R^d . Расстояние

$$KL(P||Q) = \int_{R^d} p(x) \log \frac{p(x)}{q(x)}.$$

Дивергенция Кульбака-Лейблера дает возможность перейти к перекрестной энтропии (cross-entropy)

$$H(p, q) = E_p[-\log(q)] = - \sum_x p(x) \log(q(x)).$$