

МАТЕМАТИЧЕСКИЕ ОСНОВЫ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Каганов Ю.Т.

ЛЕКЦИЯ № 11

Методы линейной алгебры в машинном обучении

От матричных операций к снижению размерности и сжатию данных

Содержание

- Введение: Почему линейная алгебра?
 - Матрицы и тензоры – язык данных
 - Собственные значения и векторы – внутренняя структура
 - SVD – "фундаментальная теорема" линейной алгебры
 - PCA и ZCA – классические методы понижения размерности
 - Применение в ML: от изображений до NLP
- Заключение

Введение

- Данные представляются как векторы, матрицы, тензоры.
- Параметры моделей (веса нейросетей) – это матрицы.
- Преобразования данных (сдвиг, масштабирование, проекция) – линейные операции.
- **Ключевая мысль:** Линейная алгебра – это "инфраструктурный" язык для описания вычислений в ML.

Матрицы: организованные данные

- **Определение:** Прямоугольная таблица чисел. Размерность: [строки × столбцы].
- **Примеры в ML:**
 - Датасет с n объектами и m признаками → матрица $[n \times m]$.
 - Веса линейного слоя в нейросети: [входные_нейроны × выходные_нейроны].
 - **Визуализация:** Таблица данных (объекты-признаки).

Тензоры: обобщение матриц

- **Определение:** Многомерный массив чисел. Нулевая размерность – скаляр, 1 – вектор, 2 – матрица, 3+ – тензор.
- **Примеры в ML:**
 - Черно-белое изображение: матрица [высота × ширина] (тензор 2D).
 - Цветное изображение: тензор [высота × ширина × каналы(RGB)] (тензор 3D).
 - Пакет (batch) изображений: тензор [размер_пакета × высота × ширина × каналы] (тензор 4D).
- **Визуализация:** Рисунок: скаляр → вектор → матрица → куб (тензор 3D).

Базовые операции: где они живут в ML?

- Умножение на скаляр: масштабирование (нормализация).
- Умножение матриц (крайне важно!):
 - Линейная регрессия: $y = Xw$.
 - Преобразование признаков в нейросетях.
 - **Визуализация:** Схема умножения матрицы данных на вектор весов.

Собственные значения и собственные векторы

- **Аналогия:** Преобразование – растяжение пространства. Собственный вектор – направление, которое не меняется, а только растягивается/сжимается.
- **Формула:** $A v = \lambda v$
 - A – матрица преобразования.
 - v – собственный вектор (направление).
 - λ – собственное значение (коэффициент растяжения).
- **Визуализация:** Простая картинка с эллипсом и его осями (собственные векторы матрицы ковариации).

Как это связано с данными?

- Матрица ковариации данных C описывает форму "облака" точек.
- Собственные векторы C – это **главные направления** разброса данных.
- Собственные значения λ – это **дисперсия** (разброс) данных вдоль этих направлений.
- **Визуализация:** 2D "облако" точек с двумя ортогональными стрелками (собственные векторы), где длина стрелки пропорциональна λ .

Для чего это нужно?

- Анализ устойчивости систем.
- Критерий положительной определенности в оптимизации.
- **Главное:** Основа для методов понижения размерности (РСА).

SVD-разложение

"Фундаментальная теорема" линейной алгебры

• **Утверждение:** Любую матрицу $A [m \times n]$ можно представить в виде:

$$A = U \Sigma V^T$$

• **Расшифровка:**

• $U [m \times m]$ – левые сингулярные векторы (ортонормированный базис для пространства строк).

• $\Sigma [m \times n]$ – диагональная матрица сингулярных чисел ($\sigma_1 \geq \sigma_2 \geq \dots \geq 0$). **Мощность компонент.**

• $V [n \times n]$ – правые сингулярные векторы (ортонормированный базис для пространства столбцов).

• **Визуализация:** Схематичное разложение матрицы на три компоненты.

Геометрическая интерпретация SVD

- Любое линейное преобразование – это:
 1. Вращение/отражение в пространстве признаков (V^T).
 2. Растяжение/сжатие вдоль новых осей (Σ).
 3. Вращение/отражение в пространстве объектов (U).
- **Визуализация:** Анимация или три кадра: 1) исходный круг, 2) после V^T , 3) после Σ , 4) после U

Связь SVD с собственными числами

- Левые сингулярные векторы (U) – это собственные векторы матрицы $A A^T$.
- Правые сингулярные векторы (V) – это собственные векторы матрицы $A^T A$.
- Сингулярные числа (σ) – это квадратные корни из собственных значений этих матриц: $\sigma_i = \sqrt{\lambda_i}$.
- **Ключевой вывод:** SVD более универсален и устойчив, чем разложение по собственным векторам (работает с любыми, не только квадратными матрицами).

РСА и ZCA

- **Метод главных компонент (РСА) – идея**
- **Цель:** Найти новые ортогональные оси (главные компоненты), вдоль которых дисперсия данных максимальна.
- **Задача:** Преобразовать данные в новую систему координат, отбросить оси с малой дисперсией → уменьшить размерность с минимальными потерями информации.
- **Визуализация:** 2D облако точек, две новые оси РС1 и РС2. РС1 – направление наибольшего разброса.

Алгоритм PCA (шаги)

- 1.Центрирование данных:** Вычесть среднее по каждому признаку.
 - 2.Вычисление ковариационной матрицы:** $C = X^T X / (n-1)$.
 - 3.Собственное разложение C (или SVD X):** Находим собственные векторы (V) и значения.
 - 4.Сортировка:** Упорядочиваем компоненты по убыванию λ .
 - 5.Проекция:** Переводим данные в новое пространство: $T = X V_k$. Здесь V_k – первые k собственных векторов.
- Визуализация:** Блок-схема из 5 шагов.

РСА через призму SVD (предпочтительный способ)

- Делаем SVD для центрированной матрицы данных: $X_{\text{centered}} = U \Sigma V^T$.
- Главные компоненты (РС) – это **столбцы матрицы V** .
- Проекция (сжатые данные): $T = U \Sigma$ или $X V$.
- **Почему так лучше?** Численно более стабильно, особенно для больших или "широких" матриц.

ZCA-преобразование ("Белые пятна")

- **Цель:** Не только снизить размерность, но и получить **декоррелированные** признаки с единичной дисперсией, максимально похожие на исходные.
- **Формула:** $ZCA = U U^T$ (для данных, спроецированных на все компоненты и "отбеленных").
Часто: $X_{zca} = X V D^{-1/2} V^T$, где D — диагональная матрица собственных значений.
- **Результат:** Ковариационная матрица X_{zca} становится единичной матрицей.
- **Визуализация:** Сравнение: исходное облако (эллипс), после PCA (повернутый эллипс), после ZCA (круг, похожий на исходный).

Сравнение PCA и ZCA

- **PCA:** Поворачивает данные, находит главные оси. Используется для **сжатия и визуализации**.
- **ZCA:** "Отбеливает" данные, убирая корреляции. Используется как **предобработка** (например, в изображениях перед обучением CNN) для ускорения сходимости.
- **Визуализация:** Ряд изображений: оригинал, PCA-компоненты, ZCA-результат (похож на оригинал, но с иным распределением пикселей).

Понижение размерности: зачем?

- Борьба с "проклятием размерности".
- Сжатие данных, ускорение обучения.
- Визуализация многомерных данных (проекция на 2D/3D).
- Визуализация многомерных данных (проекция на 2D/3D).
- Удаление шума и избыточных признаков.
- Улучшение обобщающей способности модели.

Применение в обработке изображений и компьютерном зрении

- **Сжатие:** PCA для лица (Eigenfaces).
- **Предобработка:** ZCA-отбеливание в Deep Learning.
- **Выделение признаков:** SVD для упрощения матриц в классических алгоритмах.
- **Визуализация:** Пример Eigenfaces.

Применение в обработке естественного языка (NLP)

- **Latent Semantic Analysis (LSA):** SVD матрицы "термин-документ" для поиска скрытых тематик.
- **Снижение размерности векторов слов (word embeddings).**
- **Визуализация:** Схема матрицы Term-Document и ее SVD.

Применение в рекомендательных системах

- **Алгоритмы** вроде SVD (и его улучшений – SVD++, FunkSVD) для прогноза оценок в матрице "пользователь-товар".
- **Идея:** Найти скрытые (латентные) факторы пользователей и товаров.
- **Визуализация:** Матрица оценок $R \approx P Q^T$.

Помимо понижения размерности

- Решение систем линейных уравнений в линейной регрессии (МНК).
- Вычисление псевдообратной матрицы Мура-Пенроуза через SVD.
- Регуляризация (Ridge Regression) и ее связь с собственными значениями.
-

Заключение

Резюме ключевых идей

- **Данные = Тензоры.** Операции с ними – основа вычислений в ML.
- **Собственные векторы** показывают **главные направления** изменчивости данных.
- **SVD** – мощнейший инструмент разложения и анализа данных.
- **РСА & ЗСА** – практические методы, вытекающие из LA, для сжатия и предобработки.
- Эти методы – "**рабочие лошадки**" в областях от CV до NLP.

Современный контекст и развитие

- **Нейронные сети:** Автоэнкодеры – нелинейное обобщение PCA.
- **t-SNE, UMAP:** Современные методы визуализации, использующие LA на начальных этапах.
- **Тензорные разложения (CP, Tucker)** для анализа многомерных данных.
- **Ключевой вывод:** Линейная алгебра остается ядром, вокруг которого строятся даже самые сложные нелинейные модели.