

Лекция № 10

**Метаоптимизация популяционных
алгоритмов для решения задач
многокритериальной оптимизации**

ПЛАН ЛЕКЦИИ

- **Часть 1:** Введение в проблему: Многокритериальная оптимизация (МКО)
- **Часть 2:** Инструменты: Популяционные алгоритмы (ПА)
- **Часть 3:** Проблема: Настройка ПА (От искусства к науке)
- **Часть 4:** Решение: Метаоптимизация (Идеи и уровни)
- **Часть 5:** Практика: Подходы и примеры
- **Часть 6:** Заключение и вызовы будущего

Часть 1: Введение в проблему: Многокритериальная оптимизация

Мир компромиссов

Тезис: Реальные задачи редко имеют одну цель.

- **Примеры:**

Проектирование: Прочность vs. Вес vs. Стоимость.

Финансы: Доходность vs. Риск.

ML: Точность модели vs. Сложность (скорость/память).

- **Визуализация:** Коллаж из иконок, иллюстрирующих противоречивые цели.

Формальная постановка задачи МКО

- **Формула:**
- Minimize $F(x) = [f_1(x), f_2(x), \dots, f_k(x)]$ при $x \in \Omega$
- **Ключевые отличия от однокритериальной:** Нет единственного решения!
- **Визуализация:** Пространство решений и пространство критериев. Множество возможных точек $F(x)$.

Парето-оптимальность — философия баланса

- **Определение доминирования:** Решение А доминирует В, если оно не хуже по всем критериям и строго лучше хотя бы по одному.
- **Парето-оптимальное решение:** Решение, которое не доминируемо никаким другим.
- **Парето-фронт (Pareto Front, PF):** Множество значений целевых функций всех Парето-оптимальных решений в пространстве критериев.
- **Визуализация:** 2D-график с облаком точек. Явно показаны доминируемые и недоминируемые (Парето-оптимальные) точки. Линия/кривая, соединяющая последние, — это PF.

Часть 2: Инструменты: Популяционные алгоритмы

Почему популяционные алгоритмы для МКО?

- **Ключевые представители:**
 - **NSGA-II** (Non-dominated Sorting Genetic Algorithm II) — эталон.
 - **SPEA2** (Strength Pareto Evolutionary Algorithm 2).
 - **MOEA/D** (Multi-Objective Evolutionary Algorithm Based on Decomposition).
 - **PAES** (Pareto Archived Evolution Strategy).
- **Визуализация:** Иконки/логотипы алгоритмов.

Алгоритм NSGA-II

- **NSGA-II (Алгоритм генетической сортировки по недоминированию, версия II)** — это один из самых популярных и эффективных эволюционных алгоритмов для решения **многокритериальных (многоцелевых) задач оптимизации**.
- **Основная идея**
- В однокритериальной задаче мы ищем одну "лучшую" точку. В многокритериальной — несколько целей часто конфликтуют между собой (например, минимизация стоимости и максимизация надежности системы). Вместо одного решения существует набор **компромиссных решений**, известный как **Парето-оптимальный фронт**. Цель NSGA-II — найти набор решений, максимально приближенный к истинному Парето-фронту, и максимально разнообразный по нему.

Пошаговое описание алгоритма NSGA-II

- Пусть дана задача с M целями для минимизации.
- **Шаг 0: Инициализация**
Генерируется начальная популяция P_0 размером N случайных особей (решений). Устанавливается номер поколения $t = 0$.
- Далее алгоритм работает в цикле (поколениями):
- **Шаг 1: Создание потомства (Reproduction)**
Из текущей популяции P_t с помощью операторов **селекции, кроссовера (скрещивания) и мутации** создается популяция потомков Q_t того же размера N .
- **Селекция:** Для выбора родителей используется **бинарный турнирный отбор**, основанный на ранге и расстоянию переполнения (см. ниже).
- **Шаг 2: Объединение (Combination)**
Текущая популяция и популяция потомков объединяются в одну общую популяцию $R_t = P_t \cup Q_t$ размером $2N$.
- **Шаг 3: Классификация по фронтам (Non-dominated Sorting)**
Это **ключевой этап**. Объединенная популяция R_t делится на иерархические **фронты недоминирования (Парето-фронты)**.
 - **Фронт 1 (F_1):** Все решения, которые не доминируются *никем* в R_t (наилучшие).
 - **Фронт 2 (F_2):** Все решения, которые доминируются *только* решениями из F_1 , но не доминируются другими.
 - **Фронт 3 (F_3):** Доминируются решениями из F_1 и F_2 , и так далее.Этот процесс продолжается, пока все решения в R_t не будут распределены по фронтам.

Пошаговое описание алгоритма NSGA-II

- **Шаг 4: Заполнение новой популяции (Forming New Population)**

Новая популяция P_{t+1} формируется последовательным добавлением целых фронтов, начиная с наилучшего (F_1).

1. Добавляем все решения из F_1 .
2. Затем добавляем все решения из F_2 .
3. И так далее, пока добавление *целого* следующего фронта F_k не превысит размер N . То есть $|P_{t+1}| + |F_k| > N$.

- **Шаг 5: Ничья разрешение (Crowding Distance & Sorting)**

Если после добавления фронта F_{k-1} место в новой популяции P_{t+1} осталось, но его меньше, чем размер фронта F_k , необходимо выбрать **наиболее разнообразные** решения из F_k .

Для этого используется метрика **расстояние переполнения (crowding distance)**.

- **Что это?** Это оценка плотности решений вокруг данной особи. Большее расстояние означает, что соседних решений мало, и особь находится в менее "заполненной" области фронта.

- **Как считается?** Для каждого фронта F_k :

1. Для каждой цели (m) решения на фронте сортируются по значению этой цели.
2. Крайним точкам (с минимальным и максимальным значением) присваивается бесконечное расстояние (чтобы их сохранить).
3. Для внутренних точек расстояние вычисляется как нормализованная разность значений цели у соседних (в отсортированном порядке) справа и слева решений. Суммируется по всем целям.

Пошаговое описание алгоритма NSGA-II

- **Как выбираем?** Решения внутри фронта F_k сортируются по **убыванию** расстояния переполнения (предпочтение отдается более изолированным решениям). Затем из отсортированного списка F_k берется ровно столько лучших решений, сколько нужно, чтобы заполнить популяцию P_{t+1} до размера N .
- **Шаг 6: Итерация**
Увеличиваем $t = t + 1$. Новая популяция P_{t+1} становится текущей.
Возвращаемся к **Шагу 1**. Цикл повторяется до выполнения условия остановки (например, достижение максимального числа поколений).

Схематично один цикл (поколение) можно представить так:

- P_t (Родители, размер N) + Q_t (Потомки, размер N)
- $\downarrow$
- $R_t = P_t \cup Q_t$ (Размер $2N$)
- $\downarrow$
- Не-доминирующая Сортировка $R_t \rightarrow [F_1, F_2, F_3, \dots]$
- $\downarrow$
- Формирование P_{t+1} : Берем $F_1, F_2, \dots$ пока не заполним
- N мест.
- $\downarrow$
- Если места не хватает $\rightarrow$ Сортировка по Crowding Distance внутри последнего фронта.
- $\downarrow$
- P_{t+1} (Новая популяция, размер N)

Ключевые преимущества NSGA-II:

1. **Элитизм:** Сохранение лучших решений из поколения в поколение (через объединение R_t).
2. **Явная стратегия разнообразия:** Использование **расстояния переполнения** позволяет равномерно распределять решения по Парето-фронту, избегая скученности.
3. **Вычислительная эффективность:** Алгоритм имеет сложность $O(M * N^2)$, что лучше, чем у предшественника NSGA ($O(M * N^3)$), благодаря эффективной процедуре недоминирующей сортировки.
4. **Отсутствие параметра "ниша":** В отличие от многих других алгоритмов, NSGA-II не требует ручной настройки параметра размера ниши, используя вместо этого crowding distance.

Итог: NSGA-II — это мощный, сбалансированный алгоритм, который одновременно **сближается с истинным Парето-фронтом** (за счет недоминирующей сортировки и элитизма) и **поддерживает разнообразие решений** на нем (за счет расстояния переполнения). Это делает его эталонным методом в области многокритериальной оптимизации.

SPEA2 (Strength Pareto Evolutionary Algorithm 2)

- **SPEA2 (Эволюционный алгоритм силы Парето, версия 2)** — это улучшенный эволюционный алгоритм для многокритериальной оптимизации, являющийся развитием оригинального алгоритма SPEA. Его основная цель — нахождение набора решений, максимально приближенного к истинному Парето-оптимальному фронту, с равномерным распределением по нему.
- **Основная идея и отличие от NSGA-II**
- В отличие от **NSGA-II**, который работает с единой популяцией и классифицирует решения по фронтам, **SPEA2** использует **элитный архив** (*archive*). Этот архив хранит наилучшие недоминируемые решения, найденные на данный момент. Отбор, кроссовер и мутация производятся с участием этого архива, что обеспечивает более сильный и направленный элитизм.

SPEA2 (Strength Pareto Evolutionary Algorithm 2)

- **Ключевые понятия и компоненты**

1. **Основная популяция (P):** Обычная популяция решений, как в классическом генетическом алгоритме.
2. **Архив (A):** Внешний набор, хранящий лучшие (недоминируемые) решения. Его размер фиксирован (обычно равен размеру основной популяции N). Это ключевой механизм элитизма.
3. **Сила особи (S(i), *Raw Fitness*):** Мера, показывающая, скольким особям из объединенной популяции ($P \cup A$) данная особь i доминирует. **Чем меньше значение силы, тем лучше** (идеал = 0 для недоминируемой особи).
4. **Плотность (D(i), *Density Estimation*):** Дополнительная мера, оценивающая "скученность" окрестности особи. Используется для разрешения ничьих между особями с одинаковой силой. Рассчитывается через расстояние до k -го ближайшего соседа. **Чем меньше плотность, тем лучше** (больше свободного пространства вокруг).

Схематично один цикл (поколение) можно представить так:

- $P_t(N)$ $A_t(N_A)$



Объединенная популяция $P_t \cup A_t (N + N_A)$



Расчет приспособленности $F(i)=R(i)+D(i)$



Отбор недоминируемых в архив-кандидат



Если $|\text{Архив}| > N_A \rightarrow$ Прореживание (Truncation)

Если $|\text{Архив}| < N_A \rightarrow$ Дозаполнение лучшими



A_{t+1} (Обновленный архив, размер N_A)



Турнирный отбор из $A_{t+1} \rightarrow$ Кроссовер/Мутация



P_{t+1} (Новая основная популяция)

Ключевые особенности и преимущества SPEA2 (по сравнению с первой версией и NSGA-II):

1. **Усовершенствованная мера приспособленности:** Используется комбинация *силы* (R) и *плотности* (D), что дает более точную градацию решений, особенно когда много недоминируемых особей.
 2. **Точная оценка плотности:** Использование расстояния до k-го ближайшего соседа (вместо обратного расстояния до фиксированной n-й особи в SPEA1) более надежно и менее подвержено случайным выбросам.
 3. **Детерминированный метод прореживания архива:** Процедура удаления особей с минимальным расстоянием до соседа гарантирует сохранение граничных решений и поддержание разнообразия, даже когда архив переполнен недоминируемыми решениями.
 4. **Постоянный и сильный элитизм:** Архив целенаправленно хранит и передает в следующие поколения только лучшие найденные решения.
 5. **Вычислительная сложность:** Основные операции (расчет расстояний для плотности и прореживания) имеют сложность $O((N+N_A)^2 * M)$, что сравнимо с $O(M*N^2)$ в NSGA-II.
- **Итог:** SPEA2 — это мощный алгоритм, особенно эффективный в задачах, где важно поддерживать стабильный и разнообразный набор Парето-оптимальных решений. Его механизм внешнего архива и усовершенствованные метрики приспособленности делают его надежной альтернативой NSGA-II, часто показывающей лучшие результаты на задачах со сложными формами фронтов или большим числом целей.
 -

MOEA/D (Multi-Objective Evolutionary Algorithm Based on Decomposition)

- **MOEA/D (Multi-Objective Evolutionary Algorithm Based on Decomposition)** — это многокритериальный эволюционный алгоритм, основанный на декомпозиции. В отличие от NSGA-II и SPEA2, которые используют понятие доминирования по Парето для сравнения решений, MOEA/D разбивает многокритериальную задачу на множество скалярных подзадач (обычно с помощью метода взвешенных сумм, метода Чебышёва или других методов агрегирования). Затем эти подзадачи решаются одновременно в рамках одной популяции, где каждое решение ассоциировано с одной подзадачей.

PAES (Pareto Archived Evolution Strategy)

- **PAES (Эволюционная стратегия с архивом Парето)** — это один из первых и наиболее влиятельных алгоритмов многокритериальной оптимизации, который представил несколько фундаментальных концепций, ставших стандартом в этой области. Его ключевые особенности — **использование внешнего архива для хранения недоминируемых решений** и **инновационный механизм поддержания разнообразия** на основе адаптивной решетки.
- PAES — это **(1+1)-эволюционная стратегия** для многокритериальной оптимизации:
- **"1+1"**: Алгоритм работает с **одной особью-родителем** и создает **одного потомка** за итерацию.
- **"Эволюционная стратегия"**: Использует механизмы, характерные для классических эволюционных стратегий (мутация с адаптацией параметров).
- **"С архивом Парето"**: Все найденные недоминируемые решения сохраняются во внешнем неизменяемом архиве.
- PAES решает две ключевые проблемы:
 1. Как сравнивать родителя и потомка в многокритериальной среде.
 2. Как поддерживать разнообразие решений в архиве ограниченного размера.

Ключевые концепции

1. **Внешний архив (Pareto Archive):** Хранит все найденные недоминируемые решения. Основная цель — сохранять Парето-оптимальные решения по мере их обнаружения.
2. **Адаптивная решетка (Adaptive Grid):** Механизм для поддержания разнообразия и ограничения размера архива. Пространство целевых функций разбивается на гиперкубы (ячейки). Решения, попадающие в одну ячейку, считаются "похожими".
3. **Плотность ячейки (Crowding Degree):** Количество решений в конкретной ячейке решетки. Используется для принятия решений при переполнении архива.

Ключевые инновации и преимущества PAES:

1. **Простота и минимализм:** (1+1)-подход делает алгоритм очень простым для реализации и анализа.
2. **Первый алгоритм с адаптивной решеткой:** Ввел идею пространственного разделения для поддержания разнообразия, которая повлияла на развитие области.
3. **Явное разделение текущей особи и архива:** Архив хранит историю лучших решений, а поиск ведется одной текущей особью.
4. **Эффективность для быстрого поиска:** Требуется мало вычислений на итерацию, поэтому может быстро найти хорошие приближения.

Недостатки и ограничения:

1. **Низкая скорость сходимости:** (1+1)-стратегия не использует преимущества популяционных методов (рекомбинацию, параллельный поиск).
2. **Чувствительность к параметру решетки k :** Качество распределения решений сильно зависит от выбора этого параметра.
3. **Проблемы с масштабированием:** При увеличении числа целей (>3) эффективность решеточного подхода снижается ("проклятие размерности").
4. **Отсутствие рекомбинации:** Не использует скрещивание, что ограничивает исследовательские возможности.

Вариации PAES:

1. **$(1+\lambda)$ -PAES**: Использует λ потомков на итерацию, выбирая лучшего.
 2. **$(\mu+\lambda)$ -PAES**: Полноценная популяционная версия.
 3. **PHC (Pareto Hill Climber)**: Упрощенная версия без адаптивной решетки.
- **Историческое значение и влияние:** PAES, предложенный Джошуа Ноулом (Joshua Knowles) и Дэвидом Корном (David Corne) в 1999 году, стал **первым алгоритмом, использующим внешний архив и механизм ниши на основе решетки**. Его идеи легли в основу более поздних и совершенных алгоритмов, таких как **SPEA2** (где решетка была заменена на k -го ближайшего соседа) и **PESA** (Population-based ESA).
 - **Итог:** PAES — это элегантный минималистичный алгоритм, который ввел в многокритериальную оптимизацию несколько фундаментальных концепций. Хотя современные алгоритмы (NSGA-II, SPEA2, MOEA/D) обычно превосходят его по эффективности, PAES остается важной вехой в истории развития области и полезным инструментом для простых задач или когда требуется быстрый прототип.

Часть 3: Проблема: Настройка ПА (От искусства к науке)

Гиперпараметры ПА — что можно настраивать?

- **Популяционные:** Размер популяции (N), число поколений.
- **Операторы поиска:**
 - Для **ГА**: Вероятности кроссовера (p_c) и мутации (p_m), их типы (SBX, PM).
 - Для **DE**: Весовой коэффициент (F) и вероятность кроссовера (CR).
 - Для **PSO**: Коэффициенты инерции, когнитивный и социальный.
- **Визуализация:** Таблица с группами параметров и их типичными диапазонами.

Сложность ручной настройки

- **Проблема 1: Нет универсальных настроек.** Оптимальные параметры зависят от задачи (размерность, форма RF, тип функций).
- **Проблема 2: Взаимовлияние.** Параметры сильно коррелированы.
- **Проблема 3: Высокая стоимость.** Каждый прогон алгоритма — дорогое вычисление $F(x)$ тысячи раз.
- **Вывод:** Ручная настройка методом проб и ошибок неэффективна и ненаучна.

Часть 4: Решение: Метаоптимизация (Идеи и уровни)

Что такое метаоптимизация?

- **Идея:** Использовать внешний *мета-алгоритм* для автоматического поиска наилучших параметров *базового* алгоритма.
- **Формально:** $\theta^* = \operatorname{argmin} J(\theta)$, где
 - θ — вектор параметров настраиваемого ПА (например, $[N, p_c, p_m]$).
 - $J(\theta)$ — *мета-функция* (критерий эффективности ПА с параметрами θ на целевой задаче).
- **Визуализация:** Двухуровневая схема: Мета-алгоритм $\rightarrow$ (настройка θ) $\rightarrow$ Базовый ПА $\rightarrow$ (оценка на задаче) $\rightarrow$ Значение $J(\theta)$.

Ключевой вопрос: Как оценивать эффективность? ($J(\theta)$)

- **Метрики качества Парето-приближения:**
 - **Hypervolume (HV, S-метрика):** Объем пространства, доминируемый PF. Золотой стандарт. Чем больше, тем лучше.
 - **Inverted Generational Distance (IGD):** Среднее расстояние от точек истинного PF до найденного. Чем меньше, тем лучше.
- **Выбор мета-функции:** $J(\theta) = -HV(A(\theta))$ или $J(\theta) = IGD(A(\theta))$, где $A(\theta)$ — результат работы алгоритма с настройками θ .
- **Визуализация:** Графическое объяснение Hypervolume для 2D случая.

Уровни метаоптимизации (Offline, Online, Meta-control)

- **Offline (обучающая выборка):** Настройка θ раз и навсегда на наборе *тренировочных* задач. Цель — хорошая **обобщающая способность**.
- **Online (в процессе решения):** Настройка θ динамически, в ходе решения *одной конкретной* задачи.
- **Meta-control:** Настройка не параметров, а *правил их адаптации* (например, стратегии изменения p_m от поколения к поколению).
- **Визуализация:** Сравнительная схема трех подходов.

Часть 5: Практика: Подходы и примеры

Выбор мета-алгоритма

- **Критерии:** Эффективность при малом числе вызовов дорогой $J(\theta)$, работа с непрерывными/дискретными θ .
- **Кандидаты:**
 - **Байесовская оптимизация (ВО):** Идеально для дорогих black-box функций. Использует суррогатную модель (GP).
 - **Другие ПА (меметика):** Например, настройка DE с помощью GA.
 - **Методы основанные на градиентах:** Если $J(\theta)$ дифференцируема (редко).
- **Визуализация:** Логотипы/названия методов.

Пример 1: Offline-настройка с помощью Байесовской оптимизации

- **Цель:** Найти θ для NSGA-II, максимизирующий средний Hypervolume на наборе тестовых функций (ZDT, DTLZ).
- **Шаги:**
 1. Определить пространство параметров θ (диапазоны для p_c , p_m , η_c , η_m).
 2. Создать суррогатную модель $J(\theta)$ по результатам нескольких прогонов.
 3. Использовать функцию приобретения (EI, UCB) для выбора новой перспективной точки θ .
 4. Повторять, пока не исчерпан бюджет мета-оптимизации.
- **Визуализация:** График сходимости ВО, сравнение PF до и после настройки.

Пример 2: Online-адаптация (Self-Adaptive DE для МКО)

- **Идея:** Включить параметры F и CR в хромосому и эволюционировать их вместе с переменными задачи.
- **Как:** Каждая особь имеет свои F_i и CR_i . Успешные особи передают свои параметры потомкам.
- **Преимущество:** Автоматическая подстройка к различным этапам поиска (исследование/использование).
- **Визуализация:** Схема модифицированной хромосомы и процесса наследования параметров.

Пример 3: Настройка операторов (Adaptive Operator Selection)

- **Проблема:** Какой оператор мутации лучше применить *сейчас*?
- **Решение (Credit Assignment):** Давать "кредит" оператору, если он создал хорошее потомство.
- **Выбор (Probability Matching):** Выбирать оператор с вероятностью, пропорциональной его накопленному кредиту.
- **Визуализация:** Схема адаптивного выбора из пула операторов (Polynomial Mutation, Uniform Mutation и др.).

Пример 4: Метаоптимизация в промышленности (Кейс)

- **Задача:** Оптимизация аэродинамического профиля.
- **Критерии:** $f1$ — подъемная сила (максимизировать), $f2$ — лобовое сопротивление (минимизировать).
- **Проблема:** Один вызов симулятора (CFD) — минуты/часы.
- **Решение:** Offline-настройка алгоритма MOEA/D на быстрых аналитических моделях (суррогатах), затем применение с найденными параметрами к дорогой симуляции.

Часть 6: Заключение и вызовы будущего

Преимущества метаоптимизированных алгоритмов

- **Автоматизация:** Уход от ручных "костылей".
- **Робастность:** Лучшая работа на широком классе задач.
- **Эффективность:** Достижение лучшего качества RF при том же вычислительном бюджете.
- **Воспроизводимость:** Научный подход к настройке.

Текущие проблемы и вызовы (Open Problems)

1. **"Мета-зависимость"**: Настройка самого мета-алгоритма (гипер-гиперпараметры).
2. **Перенос настроек (Transfer Learning)**: Как настройки с одних задач помогут на новых?
3. **Высокая вычислительная стоимость**: Метаоптимизация — это оптимизация в квадрате.
4. **Интерпретируемость**: Почему данный набор θ оказался лучшим?

Тренды и будущее

- **Метаоптимизация + ИИ:** Использование глубокого обучения для предсказания хороших параметров по свойствам задачи.
- **Алгоритм-конфигураторы общего назначения:** (например, irace, SMAC).
- **Фокус на many-objective оптимизацию** (более 3 критериев).
- **Облачные и распределенные метаоптимизационные фреймворки.**

Заключение

- МКО — адекватная модель реальных задач.
- ПА — мощный инструмент для МКО, но их эффективность критически зависит от параметров.
- **Метаоптимизация** — системный ответ на проблему настройки.
- Это активно развивающаяся область на стыке оптимизации и машинного обучения.

Гибридные алгоритмы и современные тенденции

- **Проблема:** У каждого алгоритма есть свои недостатки.
- **Решение:** Создание гибридных методов.
 - **ABC + локальный поиск:** Для ускорения финальной сходимости.
 - **BFO + PSO/FA:** Для ускорения процесса хемотаксиса.
 - **FA + дифференциальная эволюция:** Для улучшения механизма исследования.
- **Тренды:** Параллельные реализации (GPU), применение в машинном обучении (feature selection), оптимизация глубоких нейросетей.

Список литературы и источники

- Карпенко А. П., (2014). *Современные алгоритмы поисковой оптимизации.* – М.: МГТУ, 2014.
- Дэн Саймон, (2020). *Алгоритмы эволюционной оптимизации.* М.: ДМК Пресс, 2020.
- Passino, K.M. (2002). *Biomimicry of bacterial foraging for distributed optimization and control.* IEEE Control Systems Magazine.
- Yang, X.S. (2008). *Nature-Inspired Metaheuristic Algorithms.* Luniver Press.
- Статьи с сайтов: arXiv, ResearchGate, Scholar Google.