

План курса лекций (16 лекций)

"Современные методы оптимизации в теории принятия решений и искусственного интеллекта"

БЛОК I. ОСНОВЫ И КЛАССИЧЕСКИЕ МЕТОДЫ (Лекции 1-4)

Лекция 1. Введение в оптимизацию и принятие решений

Содержание:

- Основные понятия: целевая функция, ограничения, допустимое множество, оптимум
- Классификация задач оптимизации: линейные, нелинейные, выпуклые, невыпуклые
- Условия оптимальности: необходимые и достаточные условия (теорема Ферма, Вейерштрасса)
- Градиент, гессиан, условия первого и второго порядка
- Задачи принятия решений в ИИ: обучение моделей, гиперпараметрическая оптимизация, планирование

Математический аппарат:

$$\min f(x) \text{ subject to: } g_i(x) \leq 0, h_j(x) = 0$$

$$x \in \mathbb{R}^n$$

Условия КТТ (Каруша-Куна-Таккера):

$$\nabla f(x^*) + \sum \lambda_i \nabla g_i(x^*) + \sum \mu_j \nabla h_j(x^*) = 0$$

$$\lambda_i \geq 0, \lambda_i \cdot g_i(x^*) = 0 \text{ (complementary slackness)}$$

Примеры из ИИ:

Обучение линейной регрессии как задача минимизации MSE

Support Vector Machines как задача квадратичного программирования

Лекция 2. Методы безусловной оптимизации

Содержание:

- Градиентный спуск (Gradient Descent): batch, mini-batch, stochastic
- Метод наискорейшего спуска (Steepest Descent)
- Метод сопряженных градиентов (Conjugate Gradient)
- Квазиньютоновские методы: BFGS, L-BFGS
- Метод Ньютона и модификации (Levenberg-Marquardt)
- Условия сходимости, скорость сходимости (линейная, сверхлинейная, квадратичная)

Математический аппарат:

text

Градиентный спуск:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Метод Ньютона:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

BFGS (аппроксимация Hessian):

$$B_{k+1} = B_k + (y_k y_k^T) / (y_k^T s_k) - (B_k s_k s_k^T B_k) / (s_k^T B_k s_k)$$

где $s_k = x_{k+1} - x_k$, $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$

Примеры из ИИ:

Обучение нейронных сетей: SGD, momentum, Nesterov

Оптимизация функций потерь в deep learning

Лекция 3. Линейное и квадратичное программирование

Содержание:

- Постановка задачи линейного программирования (LP)
- Симплекс-метод: геометрическая интерпретация, алгоритм, вырожденные случаи
- Двойственность: теоремы двойственности, экономическая интерпретация
- Задача квадратичного программирования (QP)
- Методы решения QP: активных множеств, внутренней точки (interior point)
- Квадратичные формы, положительная определенность

Математический аппарат:

LP: $\min c^T x$ subject to: $Ax \leq b, x \geq 0$

Двойственная задача:

$\max b^T y$ subject to: $A^T y \geq c, y \geq 0$

QP: $\min (1/2)x^T Q x + c^T x$ subject to: $Ax \leq b$

Условия КТТ для QP:

$$Qx^* + c + A^T \lambda = 0$$

$$Ax^* \leq b, \lambda \geq 0, \lambda^T (Ax^* - b) = 0$$

Примеры из ИИ:

Portfolio optimization

SVM как задача QP: $\max \sum \alpha_i - (1/2) \sum \sum \alpha_i \alpha_j y_i y_j K(x_i, x_j)$

Задачи распределения ресурсов

Лекция 4. Выпуклая оптимизация и методы с ограничениями

Содержание:

- Выпуклые множества и функции: определение, свойства, критерии
- Субградиенты и субдифференциалы
- Метод проекции градиента (Projected Gradient)
- Метод множителей Лагранжа
- Методы штрафных функций (penalty methods): внешний, внутренний
- Метод барьерных функций (barrier methods)
- Расширенный метод Лагранжа (Augmented Lagrangian, ADMM)

Математический аппарат:

Функция Лагранжа:

$$L(x, \lambda, \mu) = f(x) + \sum \lambda_i g_i(x) + \sum \mu_j h_j(x)$$

Метод штрафов:

$$\min f(x) + \rho \sum \max(0, g_i(x))^2 + \rho \sum h_j(x)^2$$

ADMM (Alternating Direction Method of Multipliers):

$$x_{\{k+1\}} = \operatorname{argmin}_x L_\rho(x, z_k, y_k)$$

$$z_{\{k+1\}} = \operatorname{argmin}_z L_\rho(x_{\{k+1\}}, z, y_k)$$

$$y_{\{k+1\}} = y_k + \rho(Ax_{\{k+1\}} + Bz_{\{k+1\}} - c)$$

Примеры из ИИ:

- Regularization в машинном обучении (Lasso, Ridge)
- Constraint satisfaction problems
- Распределенная оптимизация в федеративном обучении (ADMM)

БЛОК II. АДАПТИВНЫЕ МЕТОДЫ И ОПТИМИЗАЦИЯ В DEEP LEARNING (Лекции 5-6)

Лекция 5. Адаптивные методы оптимизации для глубокого обучения

Содержание:

Проблемы классического SGD: плато, седловые точки, плохая обусловленность

- Momentum и Nesterov Accelerated Gradient (NAG)
- Адаптивные методы: AdaGrad, RMSProp, Adam, AdaMax
- Вариации Adam: AMSGrad, AdaBound, RAdam, Lookahead
- Второй порядок: Shampoo, K-FAC (Kronecker-Factored Approximate Curvature)
- Learning rate scheduling: step decay, exponential, cosine annealing

Математический аппарат:

- Momentum:

$$v_t = \beta v_{\{t-1\}} + (1-\beta)\nabla f(x_t)$$

$$x_{\{t+1\}} = x_t - \alpha v_t$$
- Adam:

$$m_t = \beta_1 m_{\{t-1\}} + (1-\beta_1)\nabla f(x_t) \quad [\text{first moment}]$$

$$v_t = \beta_2 v_{\{t-1\}} + (1-\beta_2)(\nabla f(x_t))^2 \quad [\text{second moment}]$$

$$\hat{m}_t = m_t / (1-\beta_1^t), \quad \hat{v}_t = v_t / (1-\beta_2^t) \quad [\text{bias correction}]$$

$$x_{t+1} = x_t - \alpha \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$$

- AdaBound:
Clip learning rate: $\alpha_t \in [\eta_l(t), \eta_u(t)]$
где η_l , η_u сходятся к постоянному LR

Примеры из ИИ:

- Обучение глубоких нейронных сетей: ResNet, Transformers
- Стабилизация обучения GAN
- Transfer learning и fine-tuning

Лекция 6. Стохастическая оптимизация и variance reduction

Содержание:

- Стохастическая аппроксимация и условия Роббинса-Монро
- Анализ сходимости SGD: bias-variance tradeoff
- Методы снижения дисперсии (variance reduction):
- SVRG (Stochastic Variance Reduced Gradient)
- SAGA
- SAG (Stochastic Average Gradient)
- Importance sampling в стохастической оптимизации
- Distributed SGD: data parallelism, model parallelism
- Asynchronous SGD, Hogwild!

Математический аппарат:

- SGD сходимость:
 $E[\|x_T - x^*\|^2] = O(1/\sqrt{T})$ [nonconvex]
 $E[f(x_T) - f^*] = O(1/T)$ [strongly convex]
- SVRG:
 $\tilde{x} = \text{snapshot}, \mu = \nabla f(\tilde{x})$
 $x_{t+1} = x_t - \alpha[\nabla f_i(x_t) - \nabla f_i(\tilde{x}) + \mu]$

Variance: $\text{Var}[\text{gradient}] = O(1/n)$ vs $O(1)$ для SGD

Distributed SGD с N workers:

$g_{\text{global}} = (1/N)\sum_i g_i$ [synchronous]

или lock-free updates [asynchronous]

Примеры из ИИ:

- Large-scale learning на больших датасетах (ImageNet)
- Распределенное обучение в кластерах GPU
- Online learning и streaming data

БЛОК III. ПОПУЛЯЦИОННЫЕ И МЕТАЭВРИСТИЧЕСКИЕ МЕТОДЫ

(Лекции 7-9)

Лекция 7. Генетические алгоритмы и эволюционные стратегии

Содержание:

- Принципы эволюционных вычислений: отбор, скрещивание, мутация
- Генетические алгоритмы (GA): представление, операторы, схемы
- Эволюционные стратегии (ES): (μ, λ) -ES, $(\mu + \lambda)$ -ES
- Самоадаптация параметров: CMA-ES (Covariance Matrix Adaptation)
- Дифференциальная эволюция (Differential Evolution)
- Генетическое программирование

Математический аппарат:

GA:

1. Инициализация популяции: $P = \{x_1, \dots, x_N\}$
2. Оценка fitness: $F(x_i)$
3. Селекция: $p_{\text{select}}(x_i) \propto F(x_i)$ [roulette wheel, tournament]
4. Crossover: $x_{\text{child}} = \alpha x_{\text{parent1}} + (1-\alpha)x_{\text{parent2}}$
5. Mutation: $x' = x + N(0, \sigma^2)$

CMA-ES:

$$x_{\{k+1\}} \sim N(m_k, \sigma_k^2 C_k)$$

где C_k — адаптивная ковариационная матрица

$$m_{\{k+1\}} = m_k + \sigma_k \sum w_i y_i \text{ [weighted recombination]}$$

$$C_{\{k+1\}} = (1-c)C_k + c \cdot \sum w_i y_i y_i^T \text{ [covariance update]}$$

Differential Evolution:

$$v_i = x_{r1} + F(x_{r2} - x_{r3}) \text{ [mutation]}$$

$$u_i = \text{crossover}(x_i, v_i) \text{ [recombination]}$$

Примеры из ИИ:

- Нейроэволюция: эволюция архитектур и весов сетей (NEAT, HyperNEAT)
- AutoML: Neural Architecture Search (NAS)
- Гиперпараметрическая оптимизация
- Обучение агентов в reinforcement learning без градиентов

Лекция 8. Роевой интеллект: PSO, ACO и другие

Содержание:

- Оптимизация роем частиц (Particle Swarm Optimization, PSO)
- Модификации PSO: CPSO, APSO, quantum PSO
- Алгоритм муравьиной колонии (Ant Colony Optimization, ACO)
- Алгоритм пчелиной колонии (Artificial Bee Colony, ABC)
- Алгоритм светлячков (Firefly Algorithm)

- Алгоритм серых волков (Grey Wolf Optimizer)
- Сравнительный анализ: No Free Lunch Theorem

Математический аппарат:

PSO:

$$v_i(t+1) = \omega \cdot v_i(t) + c_1 r_1 (p_i - x_i(t)) + c_2 r_2 (g - x_i(t))$$

$$x_i(t+1) = x_i(t) + v_i(t+1)$$

где:

- p_i — лучшая позиция частицы i (personal best)
- g — глобальный лучший (global best)
- ω — инерционный вес
- c_1, c_2 — когнитивный/социальный коэффициенты
- $r_1, r_2 \sim U[0,1]$

ACO (для TSP):

$$\tau_{ij}(t+1) = (1-\rho)\tau_{ij}(t) + \sum_k \Delta\tau_{ij}^k \text{ [pheromone update]}$$

$$p_{ij}^k = [\tau_{ij}^\alpha \cdot \eta_{ij}^\beta] / \sum_l [\tau_{il}^\alpha \cdot \eta_{il}^\beta] \text{ [transition probability]}$$

где τ — феромон, η — эвристика ($1/\text{distance}$)

Примеры из ИИ:

- Комбинаторная оптимизация: TSP, routing, scheduling
- Feature selection в ML
- Кластеризация данных
- Робототехника: swarm robotics, path planning

Лекция 9. Байесовская оптимизация и surrogate-based методы

Содержание:

- Проблема дорогостоящих функций (expensive black-box optimization)
- Байесовская оптимизация: Gaussian Processes как surrogate model
- Acquisition functions: Expected Improvement (EI), Upper Confidence Bound (UCB), Probability of Improvement (PI)
- Thompson sampling
- Multi-fidelity optimization
- Методы на основе радиальных базисных функций (RBF)
- Kriging и DACE (Design and Analysis of Computer Experiments)

Математический аппарат:

Gaussian Process:

$$f(x) \sim GP(\mu(x), k(x, x'))$$

Posterior после наблюдений $D = \{(x_i, y_i)\}$:

$$f(x)|D \sim N(\mu_D(x), \sigma_D^2(x))$$

$$\mu_D(x) = \mu(x) + k(x)^T K^{-1}(y - \mu)$$

$$\sigma_D^2(x) = k(x, x) - k(x)^T K^{-1} k(x)$$

Expected Improvement:

$$EI(x) = E[\max(f(x) - f^*, 0)] = (\mu(x) - f^*)\Phi(Z) + \sigma(x)\phi(Z)$$

где $Z = (\mu(x) - f^*)/\sigma(x)$

UCB (Upper Confidence Bound):

$$UCB(x) = \mu(x) + \kappa\sigma(x)$$

Примеры из ИИ:

- Гиперпараметрическая оптимизация: Hyperopt, Optuna, SMAC
- Neural Architecture Search (NAS-Bench)
- AutoML pipelines
- Reinforcement learning: sample-efficient policy search

БЛОК IV. МНОГОКРИТЕРИАЛЬНАЯ И МНОГОЭКСТРЕМАЛЬНАЯ ОПТИМИЗАЦИЯ (Лекции 10-12)

Лекция 10. Многокритериальная оптимизация: теория и классические методы

Содержание:

- Постановка многокритериальной задачи (MOP): Парето-оптимальность
- Парето-фронт, доминирование, недоминируемые решения
- Скаляризация: взвешенная сумма, ϵ -constraint, целевое программирование
- Метод идеальной точки (ideal point, utopia point)
- TOPSIS (Technique for Order Preference by Similarity to Ideal Solution)
- Аналитический иерархический процесс (АИП)
- Теория полезности, функции ценности

Математический аппарат:

$$\text{MOP: } \min F(x) = [f_1(x), f_2(x), \dots, f_m(x)]^T$$

subject to: $x \in X$

Парето-доминирование:

$$x_1 \prec x_2 \Leftrightarrow \forall i: f_i(x_1) \leq f_i(x_2) \text{ и } \exists j: f_j(x_1) < f_j(x_2)$$

Взвешенная сумма:

$\min \sum w_i f_i(x)$, где $\sum w_i = 1$, $w_i \geq 0$

ε -constraint:

$\min f_k(x)$

subject to: $f_i(x) \leq \varepsilon_i \quad \forall i \neq k$

Tchebycheff метод:

$\min \max_i \{w_i |f_i(x) - z_i^*|\}$

где z^* — ideal point

Примеры из ИИ:

- Multi-objective neural architecture search
- Балансировка точности и вычислительной сложности моделей
- Fairness в ML: trade-off между accuracy и fairness metrics
- Resource allocation в multi-agent systems

Лекция 11. Эволюционные многокритериальные алгоритмы

Содержание:

- NSGA-II (Non-dominated Sorting Genetic Algorithm)
- SPEA2 (Strength Pareto Evolutionary Algorithm)
- MOEA/D (Multi-Objective Evolutionary Algorithm based on Decomposition)
- Indicator-based алгоритмы: SMS-EMOA, IBEA
- Метрики качества Парето-фронта: Hypervolume, IGD, spacing
- Many-objective optimization ($m > 3$ критериев)
- Preference articulation и interactive methods

Математический аппарат:

NSGA-II:

1. Non-dominated sorting: разделение на фронты $F_1, F_2, \dots$

2. Crowding distance для diversity:

$$CD_i = \sum_k (f_k^{i+1} - f_k^{i-1}) / (f_k^{\max} - f_k^{\min})$$

3. Selection: rank > crowding distance

MOEA/D:

Декомпозиция на N скалярных подзадач:

$$\min g^{\text{te}}(x|\lambda, z^*) = \max_i \{\lambda_i |f_i(x) - z_i^*|\} \quad [\text{Tchebycheff}]$$

$$\text{или } g^{\text{ws}}(x|\lambda) = \sum \lambda_i f_i(x) \quad [\text{weighted sum}]$$

Hypervolume indicator:

$$HV(A) = \text{volume}(\cup_{x \in A} [f(x), r])$$

где r — reference point

Примеры из ИИ:

- Multi-task learning: балансировка потерь разных задач
- NAS с многими критериями: accuracy, latency, energy, model size
- Робототехника: multi-objective path planning
- Ensemble learning: diversity vs. accuracy

Лекция 12. Методы глобальной оптимизации и поиск множества экстремумов

Содержание:

- Проблема локальных минимумов в невыпуклой оптимизации
- Методы случайного поиска: Multistart, Basin Hopping
- Метод ветвей и границ (Branch and Bound)
- Метод туннелирования (Tunneling Method)
- Filled Function Method
- Simulated Annealing: метрополис-критерий, режим охлаждения
- Табу-поиск (Tabu Search)
- Niching methods: crowding, fitness sharing, speciation

Математический аппарат:

Simulated Annealing:

Принятие ухудшающего решения с вероятностью:

$$p = \exp(-\Delta E/T)$$

где $\Delta E = f(x_{\text{new}}) - f(x_{\text{current}})$, T — "температура"

Режим охлаждения:

$$T_k = T_0 \cdot \alpha^k \quad [\text{geometric}]$$

$$T_k = T_0 / (1 + \beta k) \quad [\text{logarithmic}]$$

Filled Function (Ge & Qin):

$$\phi(x, x^*) = 1/(r^2 + \|x - x^*\|^2) - r \cdot \|x - x^*\|$$

минимизация ϕ помогает "выпрыгнуть" из локального минимума x^*

Fitness Sharing (для niching):

$$f'_i = f_i / \sum_j sh(d_{ij})$$

где $sh(d) = 1 - (d/\sigma_{\text{share}})^\alpha$ если $d < \sigma_{\text{share}}$

Примеры из ИИ:

Обучение нейронных сетей: избежание плохих локальных минимумов

- Adversarial examples: поиск множества атак
- Mode collapse в GANs и методы борьбы
- Многомодальная оптимизация в эволюционной робототехнике

БЛОК V. ОПТИМАЛЬНОЕ УПРАВЛЕНИЕ И ДИНАМИЧЕСКИЕ СИСТЕМЫ (Лекции 13-14)

Лекция 13. Основы оптимального управления

Содержание:

- Постановка задачи оптимального управления (ОСР)
- Принцип максимума Понтрягина (РМР)
- Уравнение Гамильтона-Якоби-Беллмана (HJB)
- Динамическое программирование Беллмана: принцип оптимальности
- Линейно-квадратичный регулятор (LQR)
- Model Predictive Control (MPC)
- Дискретное vs. непрерывное время

Математический аппарат:

ОСР (непрерывное время):

$$\min J = \int_0^T L(x(t), u(t), t) dt + \Phi(x(T))$$

subject to: $\dot{x}(t) = f(x(t), u(t), t)$

$$x(0) = x_0$$

$$u(t) \in U$$

Принцип максимума Понтрягина:

$$H(x, u, \lambda, t) = L(x, u, t) + \lambda^T f(x, u, t) \quad [\text{Hamiltonian}]$$

Необходимые условия:

$$u^* = \operatorname{argmax}_u H(x^*, u, \lambda^*, t)$$

$$\dot{x}^* = \partial H / \partial \lambda$$

$$\lambda^* = -\partial H / \partial x$$

$$\lambda^*(T) = \partial \Phi / \partial x|_{x(T)}$$

HJB уравнение:

$$-\partial V / \partial t = \min_u \{L(x, u, t) + (\partial V / \partial x)^T f(x, u, t)\}$$

$$V(x(T), T) = \Phi(x(T))$$

LQR:

$$\min \int_0^\infty (x^T Q x + u^T R u) dt$$

$$\dot{x} = Ax + Bu$$

$$\text{Решение: } u^* = -Kx, \text{ где } K = R^{-1} B^T P$$

P — решение алгебраического уравнения Риккати:

$$A^T P + PA - PBR^{-1}B^T P + Q = 0$$

Примеры из ИИ:

- Reinforcement Learning как задача оптимального управления
- Trajectory optimization в робототехнике

- Control для автономных систем
- Оптимальное управление дронами, манипуляторами

Лекция 14. Оптимальное управление в дискретном времени и связь с RL

Содержание:

- Марковские процессы принятия решений (MDP)
- Уравнение Беллмана для Value function
- Алгоритмы динамического программирования: Value Iteration, Policy Iteration
- Аппроксимация Value/Policy: function approximation
- Q-learning и связь с оптимальным управлением
- Differential Dynamic Programming (DDP)
- iLQR (iterative Linear Quadratic Regulator)
- Trajectory optimization: direct methods (shooting, collocation)

Математический аппарат:

MDP: S — states, A — actions, $P(s'|s,a)$, $R(s,a,s')$

Bellman equation:

$$V^*(s) = \max_a \{R(s,a) + \gamma \sum P(s'|s,a) V^*(s')\}$$

$$Q^*(s,a) = R(s,a) + \gamma \sum P(s'|s,a) \max_{a'} Q^*(s',a')$$

Value Iteration:

$$V_{k+1}(s) = \max_a \{R(s,a) + \gamma \sum P(s'|s,a) V_k(s')\}$$

Policy Iteration:

1. Policy Evaluation: решить V^π из $V^\pi = R^\pi + \gamma P^\pi V^\pi$

2. Policy Improvement: $\pi'(s) = \operatorname{argmax}_a Q^\pi(s,a)$

iLQR:

Локальная линеаризация динамики:

$$x_{t+1} \approx f(\bar{x}_t, \bar{u}_t) + A_t(x_t - \bar{x}_t) + B_t(u_t - \bar{u}_t)$$

Backward pass (как в LQR):

$$Q_t = L_t + f_t^T V_{t+1}$$

$$K_t = -(Q_{uu} + B_t^T V_{t+1} B_t)^{-1} (Q_{u} + B_t^T V_{t+1} A_t)$$

$$u_t = \bar{u}_t + K_t(x_t - \bar{x}_t) \text{ [feedback gain]}$$

Forward pass: симуляция с новой политикой

Примеры из ИИ:

- Deep Reinforcement Learning: DQN, A3C, PPO
- Model-based RL: planning с learned models
- Робототехника: motion planning, grasping

- Игры: AlphaGo, AlphaZero (MCTS + RL)

БЛОК VI. СПЕЦИАЛИЗИРОВАННЫЕ МЕТОДЫ И ПРИЛОЖЕНИЯ (Лекции 15-16)

Лекция 15. Методы оптимизации для специальных задач в ИИ

Содержание:

Комбинаторная оптимизация:

- Целочисленное программирование: Branch-and-Bound, Cutting Planes
- Задача коммивояжера (TSP): точные и приближенные методы
- Learning to optimize: нейронные методы для комбинаторики

Спарсная оптимизация:

- L1-регуляризация (Lasso): ISTA, FISTA
- Proximal gradient methods
- Compressed sensing

Низкоранговая оптимизация:

- Matrix completion, matrix factorization
- Nuclear norm minimization
- Билинейная оптимизация:
- Alternating minimization
- Tensor decompositions

Математический аппарат:

Целочисленное программирование:

$\min c^T x$ subject to: $Ax \leq b, x \in \mathbb{Z}^n$

Branch-and-Bound:

1. Relax: решить LP ($x \in \mathbb{R}^n$)
2. Branch: если x_i нецелое, создать две подзадачи:

$$x_i \leq \lfloor x_i \rfloor \text{ и } x_i \geq \lceil x_i \rceil$$

3. Bound: отсечь ветви с $f > \text{incumbent}$

Lasso (L1-регуляризация):

$$\min (1/2)\|Ax - b\|^2 + \lambda\|x\|_1$$

ISTA (Iterative Shrinkage-Thresholding):

$$x_{k+1} = S_{\lambda t}(x_k - tA^T(Ax_k - b))$$

где $S_{\alpha}(z) = \text{sign}(z) \cdot \max(|z| - \alpha, 0)$ [soft thresholding]

FISTA (Fast ISTA с ускорением Нестерова):

$$y_k = x_k + ((t_{k-1} - 1)/t_k)(x_k - x_{k-1})$$

$$x_{k+1} = S_{\lambda t}(y_k - tA^T(Ay_k - b))$$

Matrix Completion:

$\min \text{rank}(X)$ subject to: $X_{\Omega} = M_{\Omega}$

Convex relaxation:

$\min \|X\|_*$ subject to: $X_{\Omega} = M_{\Omega}$

где $\|X\|_* = \sum \sigma_i$ — nuclear norm (сумма сингулярных значений)

Примеры из ИИ:

- Feature selection: Lasso для отбора признаков
- Нейронная компрессия: pruning, quantization
- Recommender systems: matrix factorization (Netflix Prize)
- Computer vision: sparse coding, dictionary learning
- Combinatorial optimization: Graph Neural Networks для TSP/VRP

Лекция 16. Современные направления и Open Problems

Содержание:

- Federated learning и распределенная оптимизация:
- FedAvg, FedProx
- Privacy-preserving optimization
- Communication-efficient methods
- Meta-learning и few-shot optimization:
- MAML (Model-Agnostic Meta-Learning)
- Learning to learn
- Neural Architecture Search (NAS):
- DARTS (Differentiable Architecture Search)
- One-shot NAS, weight sharing
- Adversarial robustness:
- Min-max optimization: PGD attacks
- Certified defenses
- Quantum optimization:
- QAOA (Quantum Approximate Optimization Algorithm)
- Variational Quantum Eigensolver (VQE)

Open problems:

- Non-convex optimization theory
- Escape from saddle points
- Generalization bounds
- Optimization-generalization tradeoff

Математический аппарат:

Federated Averaging:

Server:

$$w_{t+1} = \sum_k (n_k/n) w_k^{t+1}$$

Client k:

$$w_k^{t+1} = w_t - \eta \nabla L_k(w_t) \text{ [local SGD steps]}$$

MAML (bi-level optimization):

Meta-objective:

$$\min_{\theta} \sum_{\tau} L_{\tau}(\theta - \alpha \nabla L_{\tau}(\theta))$$

Inner loop (task τ):

$$\theta_{\tau}' = \theta - \alpha \nabla L_{\tau}(\theta) \text{ [adaptation]}$$

Outer loop:

$$\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{\tau} L_{\tau}(\theta_{\tau}') \text{ [meta-update]}$$

DARTS (continuous relaxation):

Архитектура как **weighted sum операций**:

$$\bar{o}^{(i,j)} = \sum_o (\exp(\alpha_o^{(i,j)}) / \sum_o' \exp(\alpha_o'^{(i,j)})) \cdot o(x^{(i)})$$

Bi-level optimization:

$$\min_{\alpha} L_{\text{val}}(w^*(\alpha), \alpha)$$

$$\text{где } w^*(\alpha) = \operatorname{argmin}_w L_{\text{train}}(w, \alpha)$$

Min-Max для adversarial training:

$$\min_{\theta} E[\max_{\|\delta\| \leq \varepsilon} L(x + \delta, y; \theta)]$$

Решение PGD (Projected Gradient Descent):

$$\delta_{t+1} = \Pi_{\varepsilon}(\delta_t + \alpha \cdot \operatorname{sign}(\nabla_{\delta} L(x + \delta_t, y; \theta)))$$

Современные вызовы:

- Scalability: оптимизация с миллиардами параметров (GPT-3, 175B)
- Efficiency: Green AI, energy-aware optimization
- Fairness: constrained optimization для fair ML
- Interpretability: sparse, structured solutions
- Robustness: certified optimization под adversarial attacks
- AutoML: full automation от данных до deployment

Инструменты и библиотеки:

- PyTorch, TensorFlow для deep learning optimization
- JAX для automatic differentiation
- Optuna, Ray Tune для hyperparameter tuning
- CVXPY для выпуклой оптимизации
- OR-Tools для комбинаторики
- SciPy, MATLAB Optimization Toolbox

Рекомендуемая литература

Основная:

1. Boyd S., Vandenberghe L. "Convex Optimization" (2004)

2. Nocedal J., Wright S. "Numerical Optimization" (2006)
3. Goodfellow I., Bengio Y., Courville A. "Deep Learning" (2016)
4. Sutton R., Barto A. "Reinforcement Learning: An Introduction" (2018)
5. Miettinen K. "Nonlinear Multiobjective Optimization" (1999)

Дополнительная:

6. Deb K. "Multi-Objective Optimization using Evolutionary Algorithms" (2001)
7. Luke S. "Essentials of Metaheuristics" (2013)
8. Bertsekas D. "Dynamic Programming and Optimal Control" (2017)
9. Liberzon D. "Calculus of Variations and Optimal Control Theory" (2012)
10. Ruder S. "An Overview of Gradient Descent Optimization Algorithms" (2016)

Статьи:

1. Kingma & Ba "Adam: A Method for Stochastic Optimization" (2014)
2. Deb et al. "A Fast and Elitist Multiobjective GA: NSGA-II" (2002)
3. Frazier P. "A Tutorial on Bayesian Optimization" (2018)
4. Finn et al. "Model-Agnostic Meta-Learning" (ICML 2017)

Формат оценивания

Компоненты оценки:

Домашние задания (40%): 4 задания по программированию

Задание 1: Реализация градиентных методов + Adam

Задание 2: Генетический алгоритм для NAS

Задание 3: NSGA-II для многокритериальной задачи

Задание 4: Q-learning для control task

Экзамен (30%): теоретические вопросы + задачи

Курсовой проект (30%): применение методов к реальной задаче ИИ

Темы проектов (примеры):

1. Hyperparameter optimization для Transformer model
2. Multi-objective NAS для edge devices
3. Meta-learning для few-shot classification
4. Adversarial training с оптимизацией robustness-accuracy tradeoff
5. Federated learning с оптимизацией communication efficiency

Этот курс обеспечивает solid foundation в современных методах оптимизации с акцентом на практические приложения в AI/ML и теории принятия решений.